

مبانی داده کاوی

نویسنده: محرم منصوری زاده

۶ مهر ۱۴۰۵

پیشگفتار

این کتاب با هدف آموزش مبانی داده‌کاوی به دانشجویان سال‌های پایانی کارشناسی نوشته شده است. محتوای آن بر پایه دو مرجع استاندارد این حوزه تنظیم شده:

• *Tech- and Concepts Mining: Data* J. Pei, & M., Kamber, J., Han, *niques*

• *Min- Data to Introduction* V. Kumar, & M., Steinbach, P.-N., Tan, *ing*

برخلاف مراجع اصلی که دانشنامه‌ای و جامع هستند، این کتاب برای یک درس ترمی طراحی شده و تلاش شده مطالب به صورت فشرده و کاربردی ارائه شوند. در پایان هر فصل، پیاده‌سازی مثال‌ها در زبان پایتون (پیوست الف) آمده است تا خواننده بتواند مفاهیم نظری را با کد عملی تطبیق دهد.

این کتاب به صورت متن‌باز روی گیت‌هاب منتشر می‌شود و از بازخورد، اصلاحیه و مشارکت خوانندگان استقبال می‌کند.

فهرست مطالب

ب	پیشگفتار
پ	فهرست مطالب
۱	اول مبانی
۲	۱ مقدمه‌ای بر داده‌کاوی
۲	۱.۱ داده‌کاوی چیست؟
۳	۲.۱ فرآیند کشف دانش از داده
۶	۳.۱ انواع الگوهای قابل کشف
۶	۴.۱ کاربردهای داده‌کاوی
۷	۵.۱ چالش‌های داده‌کاوی
۱۱	۲ آشنایی با داده و پیش‌پردازش
۱۱	۱.۲ انواع ویژگی‌ها
۱۳	۲.۲ کیفیت داده
۱۴	۳.۲ پیش‌پردازش داده
۲۰	۴.۲ معیارهای شباهت و فاصله
۲۴	دوم یادگیری با نظارت
۲۵	۳ طبقه‌بندی: مفاهیم پایه
۲۵	۱.۳ مقدمه‌ای بر طبقه‌بندی
۲۶	۲.۳ درخت تصمیم
۲۸	۳.۳ طبقه‌بند بیز ساده
۲۹	۴.۳ ارزیابی مقدماتی

۳۱	۴	طبقه‌بندی پیشرفته و ارزیابی مدل
۳۲	۱.۴	k نزدیک‌ترین همسایه (k-NN)
۳۲	۲.۴	ماشین بردار پشتیبان (SVM)
۳۲	۳.۴	روش‌های ترکیبی (Ensemble)
۳۲	۴.۴	ارزیابی مدل
۳۳	۵	مقدمه‌ای بر رگرسیون
۳۳	۱.۵	رگرسیون در برابر طبقه‌بندی
۳۴	۲.۵	رگرسیون خطی ساده و چندگانه
۳۴	۳.۵	رگرسیون لجستیک
۳۵	۴.۵	ارزیابی مدل‌های رگرسیون
۳۷		سومادگیری بدون نظارت
۳۸	۶	قوانین انجمنی
۳۸	۱.۶	مقدمه: از یادگیری با نظارت به بدون نظارت
۳۹	۲.۶	مفاهیم پایه
۴۰	۳.۶	الگوریتم Apriori
۴۱	۴.۶	الگوریتم FP-Growth
۴۱	۵.۶	ارزیابی و انتخاب قوانین جالب
۴۳	۷	خوشه‌بندی
۴۳	۱.۷	مقدمه‌ای بر خوشه‌بندی
۴۴	۲.۷	الگوریتم k-means
۴۵	۳.۷	خوشه‌بندی سلسله‌مراتبی
۴۶	۴.۷	DBSCAN
۴۶	۵.۷	ارزیابی خوشه‌بندی
۴۸	۸	تشخیص داده‌های پرت
۴۸	۱.۸	تعریف و انواع داده‌های پرت
۴۹	۲.۸	روش‌های آماری
۴۹	۳.۸	روش‌های مبتنی بر فاصله و چگالی
۵۰	۴.۸	روش‌های مبتنی بر یادگیری

۵۲

چهارم موضوعات تکمیلی

۵۳	۹	مقدمه‌ای بر داده‌کاوی متن و وب
۵۳	۱.۹	چرا متن به رفتار متفاوتی نیاز دارد؟
۵۳	۲.۹	پیش‌پردازش متن
۵۴	۳.۹	بازنمایی متن به صورت عددی
۵۵	۴.۹	کاربردهای مقدماتی
۵۵	۵.۹	مقدمه‌ای بر داده‌کاوی وب

۵۸	۱۰	مقدمه‌ای بر داده‌های پیچیده
۵۸	۱.۱۰	فراتر از داده‌های جدولی
۵۸	۲.۱۰	داده‌کاوی گراف
۵۹	۳.۱۰	تحلیل سری‌های زمانی
۶۰	۴.۱۰	جمع‌بندی و مسیرهای پیشرفته‌تر

۶۱	آ	پایتون برای داده‌کاوی
۶۱	۱.آ	آماده‌سازی محیط
۶۱	۲.آ	فصل ۲ — پیش‌پردازش داده
۶۲	۳.آ	فصل ۳ و ۴ — طبقه‌بندی
۶۲	۴.آ	فصل ۶ — قوانین انجمنی
۶۳	۵.آ	فصل ۷ — خوشه‌بندی
۶۳	۶.آ	فصل ۸ — تشخیص داده‌های پرت
۶۳	۷.آ	فصل ۹ — داده‌کاوی متن

۶۵	ب	دیتاست‌های تمرینی
----	---	-------------------

بخش اول

مبانی

فصل ۱

مقدمه‌ای بر داده کاوی

اهداف این فصل

- درک تفاوت داده کاوی با آمار سنتی، پایگاه داده و یادگیری ماشین
- آشنایی با فرآیند کشف دانش از داده و جایگاه داده کاوی در آن
- شناخت انواع الگوهایی که می‌توان از داده استخراج کرد
- آشنایی با کاربردهای واقعی و چالش‌های اصلی داده کاوی

۱.۱ داده کاوی چیست؟

در دهه‌های اخیر، حجم داده‌های تولیدشده توسط سازمان‌ها، وبسایت‌ها، شبکه‌های اجتماعی، حسگرها و سامانه‌های تراکنشی به شکلی بی‌سابقه رشد کرده است. بانک‌ها میلیون‌ها تراکنش روزانه ثبت می‌کنند، فروشگاه‌های آنلاین رفتار خرید هر کاربر را ذخیره می‌کنند و شبکه‌های اجتماعی روزانه میلیاردها پیام و تعامل تولید می‌کنند. مسئله اصلی این نیست که داده کم است؛ برعکس، مسئله این است که در میان این حجم عظیم داده، دانش مفید و قابل اتکا چگونه استخراج شود. این دقیقاً همان مسئله‌ای است که **داده کاوی**^۱ به آن می‌پردازد. داده کاوی را می‌توان این‌گونه تعریف کرد:

داده کاوی فرآیند کشف الگوها، روابط و دانش پنهان، غیربدیهی و بالقوه مفید از میان حجم زیادی از داده است.

^۱Data Mining

سه ویژگی در این تعریف کلیدی هستند:

- **پنهان بودن:** الگوهایی که به راحتی و با نگاه ساده به داده قابل مشاهده نیستند.
- **غیربدیهی بودن:** نتیجه نباید چیزی باشد که از قبل بدیهی یا شناخته شده است (مثلاً «مشریانی که نان می‌خرند، معمولاً نان می‌خواهند» یک الگوی بی‌ارزش است).
- **مفید بودن:** الگوی کشف شده باید قابل استفاده در تصمیم‌گیری یا پیش‌بینی باشد.

داده‌کاوی در برابر آمار، پایگاه داده و یادگیری ماشین

سؤالی که معمولاً برای دانشجو پیش می‌آید این است: داده‌کاوی چه تفاوتی با آماری که پیش از این خوانده‌اید، یا با پایگاه داده و یادگیری ماشین دارد؟ پاسخ این است که داده‌کاوی یک حوزه میان‌رشته‌ای است که از هر سه این حوزه‌ها بهره می‌برد:

- از آمار، مبانی نظری برای اندازه‌گیری عدم قطعیت، آزمون فرضیه و برازش مدل را وام می‌گیرد.
- از سیستم‌های پایگاه داده، فناوری لازم برای ذخیره، بازیابی و مدیریت کارآمد حجم بزرگی از داده را می‌گیرد که اغلب در حافظه جا نمی‌شود.
- از یادگیری ماشین و هوش مصنوعی، الگوریتم‌هایی برای یادگیری خودکار الگو از داده به جای برنامه‌نویسی دستی قوانین را به کار می‌گیرد.

تفاوت اصلی داده‌کاوی با یادگیری ماشین صرف، در تمرکز آن است: یادگیری ماشین بیشتر به الگوریتم و بهینه‌سازی مدل می‌پردازد، در حالی که داده‌کاوی کل فرآیند — از داده خام تا دانش قابل استفاده — را در نظر می‌گیرد. جدول ۱.۱ این مقایسه را به طور خلاصه نشان می‌دهد.

۲.۱ فرآیند کشف دانش از داده


داده‌کاوی معمولاً به اشتباه به عنوان مترادف کل فرآیند تحلیل داده به کار می‌رود، در حالی که در واقع تنها یکی از مراحل یک فرآیند بزرگ‌تر به نام **کشف دانش از داده**^۲ است. شکل ۱.۱ این فرآیند هفت مرحله‌ای را نشان می‌دهد. جزئیات هر مرحله به شرح زیر است:

۱. **پاک‌سازی داده**^۳: حذف نویز و داده‌های ناسازگار.

^۲ Knowledge Discovery in Databases (KDD)
^۳ Data Cleaning

جدول ۱.۱: مقایسه داده کاوی با حوزه‌های نزدیک به آن

حوزه	تمرکز اصلی	سهم آن در داده کاوی
آمار	اندازه‌گیری عدم قطعیت، آزمون فرضیه، برازش مدل	مبانی نظری استنباط از داده
پایگاه داده	ذخیره، بازیابی و مدیریت کارآمد داده حجیم	زیرساخت دسترسی به داده
یادگیری ماشین	الگوریتم‌های یادگیری خودکار الگو از داده	موتور کشف الگو
داده کاوی	کل فرآیند: از داده خام تا دانش قابل استفاده	ترکیب هر سه حوزه بالا



شکل ۱.۱: مراحل هفت‌گانه فرآیند کشف دانش از داده

۲. یکپارچه‌سازی داده^۴: ترکیب داده از چند منبع مختلف.
۳. انتخاب داده^۵: بازیابی داده‌های مرتبط با هدف تحلیل.
۴. تبدیل داده^۶: تبدیل داده به قالبی مناسب برای کاوش (مثلاً از طریق تجمیع یا نرمال‌سازی).
۵. داده‌کاوی: به‌کارگیری روش‌های هوشمند برای استخراج الگو.
۶. ارزیابی الگو^۷: شناسایی الگوهای واقعاً جالب بر اساس معیارهایی مانند جالب بودن^۸.
۷. ارائه دانش^۹: نمایش دانش کشف‌شده به کاربر با استفاده از تکنیک‌های تجسم داده و گزارش‌گیری.

نکته مهم این است که در عمل، این مراحل خطی نیستند؛ فرآیند کشف دانش تکرارشونده است و معمولاً پس از ارزیابی نتایج اولیه، لازم است به مراحل پیش‌تر (مثلاً انتخاب داده یا تبدیل داده) بازگشت. در بسیاری از منابع صنعتی، نسخه ساده‌شده‌تری از این چرخه با نام CRISP-DM^{۱۰} نیز رایج است که شش مرحله دارد و به‌جای یک خط مستقیم، به‌صورت یک چرخه دیده می‌شود (شکل ۲.۱)، زیرا معمولاً پس از استقرار یک مدل در عمل، پروژه دوباره از مرحله درک کسب‌وکار آغاز می‌شود.

چرا پیش‌پردازش این قدر مهم است؟

تجربه عملی نشان می‌دهد که در اغلب پروژه‌های داده‌کاوی، بیش از ۶۰ تا ۷۰ درصد زمان صرف مراحل پاک‌سازی، یکپارچه‌سازی و تبدیل داده می‌شود، نه اجرای الگوریتم یادگیری. دلیل آن ساده است: کیفیت هر مدل داده‌کاوی مستقیماً به کیفیت داده‌ای که به آن داده می‌شود بستگی دارد؛ اصلی که با عبارت معروف «زباله وارد شود، زباله بیرون می‌آید»^{۱۱} شناخته می‌شود. جزئیات این مرحله در فصل ۲ بررسی خواهد شد.

^۴Data Integration

^۵Data Selection

^۶Data Transformation


^۷Pattern Evaluation

^۸Interestingness

^۹Knowledge Presentation

^{۱۰}Cross-Industry Standard Process for Data Mining

^{۱۱}Garbage In, Garbage Out



شکل ۲.۱: چرخه CRISP-DM به‌عنوان نسخه صنعتی و تکرارشونده فرآیند کشف دانش

۳.۱ انواع الگوهای قابل کشف

خروجی داده‌کاوی می‌تواند اشکال گوناگونی داشته باشد. به‌طور کلی، وظایف داده‌کاوی به دو دسته اصلی تقسیم می‌شوند:

- **وظایف توصیفی^{۱۲}:** هدف، شناخت ویژگی‌های کلی داده است، بدون آنکه لزوماً پیش‌بینی خاصی صورت گیرد. نمونه‌ها: خوشه‌بندی، قوانین انجمنی، تشخیص داده پرت.
- **وظایف پیش‌بینی‌کننده^{۱۳}:** هدف، استفاده از برخی ویژگی‌ها برای پیش‌بینی مقدار یک ویژگی دیگر است. نمونه‌ها: طبقه‌بندی، رگرسیون.

جدول ۲.۱ خلاصه‌ای از وظایف اصلی داده‌کاوی و فصل مرتبط با هر یک در این کتاب را نشان می‌دهد.

۴.۱ کاربردهای داده‌کاوی

داده‌کاوی امروزه در تقریباً هر صنعتی کاربرد دارد. جدول ۳.۱ چند نمونه رایج آن را نشان می‌دهد.

^{۱۲} Descriptive
^{۱۳} Predictive

جدول ۲.۱: وظایف اصلی داده‌کاوی و فصل مرتبط با هر یک در این کتاب

وظیفه	نوع	فصل مرتبط
طبقه‌بندی (Classification)	پیش‌بینی‌کننده	فصل ۳، ۴
رگرسیون (Regression)	پیش‌بینی‌کننده	فصل ۵
قوانین انجمنی (Association Rules)	توصیفی	فصل ۶
خوشه‌بندی (Clustering)	توصیفی	فصل ۷
تشخیص داده پرت (Outlier Detection)	توصیفی/پیش‌بینی‌کننده	فصل ۸

جدول ۳.۱: نمونه‌هایی از کاربرد داده‌کاوی در صنایع مختلف

حوزه	کاربرد نمونه
بانکداری و مالی	تشخیص تقلب در تراکنش‌های کارت اعتباری، امتیازدهی اعتباری ^{۱۴} مشتریان
خرده‌فروشی	تحلیل سبد خرید ^{۱۵} برای چیدمان محصولات و پیشنهاد خرید
مراقبت سلامت	پیش‌بینی ریسک بیماری بر اساس سوابق بیمار، کشف الگوهای درمانی مؤثر
بازاریابی	بخش‌بندی مشتریان ^{۱۶} ، سامانه‌های توصیه‌گر ^{۱۷}
امنیت	تشخیص نفوذ به شبکه ^{۱۸}

۵.۱ چالش‌های داده‌کاوی

با وجود پیشرفت‌های چشمگیر، داده‌کاوی همچنان با چالش‌های جدی روبه‌روست:

- **مقیاس‌پذیری:** بسیاری از الگوریتم‌های کلاسیک برای داده‌های کوچک طراحی شده‌اند و روی داده‌های بسیار بزرگ^{۱۹} کارایی کافی ندارند.
- **ابعاد بالا:** با افزایش تعداد ویژگی‌ها، بسیاری از روش‌ها دچار «نفرین ابعاد»^{۲۰} می‌شوند.
- **ناهمگونی و پیچیدگی داده:** داده‌های واقعی اغلب ترکیبی از متن، تصویر، سری زمانی و داده رابطه‌ای هستند.
- **حریم خصوصی و اخلاق داده:** استخراج الگو از داده‌های شخصی مسئولیت‌های حقوقی و اخلاقی جدی به همراه دارد.

^{۱۹} Big Data

^{۲۰} Curse of Dimensionality


- تفسیرپذیری: مدل‌های پیچیده (مانند جنگل تصادفی یا شبکه‌های عصبی) اغلب به‌صورت جعبه سیاه عمل می‌کنند و توضیح تصمیم آن‌ها دشوار است.

پیاده‌سازی در پایتون

برای آشنایی عملی، مجموعه داده کلاسیک Iris را بارگذاری کرده و یک تحلیل اکتشافی داده ساده^{۲۱} روی آن انجام می‌دهیم: رسم پراکندگی دو ویژگی «طول کاسبرگ» و «عرض کاسبرگ» برای سه گونه گل، پیش از هرگونه مدل‌سازی.

```
keywordstyle
1
2 import matplotlib.pyplot as plt
3 from sklearn.datasets import load_iris
4
5 iris = load_iris()
6 X, y, names = iris.data, iris.target, iris.target_names
7
8 fig, ax = plt.subplots(figsize=(5.5, 4.2))
9 for i, name in enumerate(names):
10     mask = y == i
11     ax.scatter(X[mask, 0], X[mask, 1], label=name.
12               capitalize())
13
14 ax.set_xlabel("Sepal_length(cm)")
15 ax.set_ylabel("Sepal_width(cm)")
16 ax.legend()
17 plt.show()
```

خروجی این کد در شکل ۳.۱ نشان داده شده است. حتی پیش از اجرای هر الگوریتم داده‌کاوی، همین نمودار ساده به‌خوبی نشان می‌دهد که گونه Setosa (نقاط آبی) بر اساس همین دو ویژگی به‌خوبی از دو گونه دیگر قابل تفکیک است، در حالی که Versicolor و Virginica همپوشانی بیشتری دارند — دقیقاً نوع بینشی که تحلیل اکتشافی داده پیش از داده‌کاوی باید فراهم کند. کد کامل‌تر این فصل، به‌همراه چند نمودار اکتشافی دیگر، در بخش «فصل ۱» پیوست الف (آ) آمده است.



شکل ۳.۱: نمودار پراکندگی طول و عرض کاسبرگ برای سه گونه مجموعه داده Iris

خلاصه فصل

در این فصل با تعریف داده کاوی، جایگاه آن در فرآیند بزرگ‌تر کشف دانش، دسته‌بندی وظایف اصلی آن به دو گروه توصیفی و پیش‌بینی‌کننده، و همچنین کاربردها و چالش‌های اصلی این حوزه آشنا شدیم. در فصل بعد، به یکی از مهم‌ترین و زمان‌برترین بخش‌های هر پروژه داده کاوی، یعنی آشنایی با داده و پیش‌پردازش آن، خواهیم پرداخت.

تمرین‌ها

۱. تفاوت میان یک الگوی «بدیهی» و یک الگوی «جالب» را با یک مثال از حوزه دلخواه خودتان توضیح دهید.
۲. برای هر یک از مراحل هفت‌گانه کشف دانش (شکل ۱.۱)، یک مثال عملی از یک پروژه فرضی (مثلاً تحلیل رفتار مشتریان یک فروشگاه آنلاین) بیاورید.
۳. چرا چرخه CRISP-DM (شکل ۲.۱) به صورت دایره‌ای ترسیم می‌شود و نه به صورت یک خط مستقیم مانند فرآیند کشف دانش؟
۴. دو مورد از وظایف داده کاوی (مثلاً طبقه‌بندی و خوشه‌بندی) را از نظر نوع (توصیفی/پیش‌بینی‌کننده) و نوع داده‌ای که نیاز دارند (برچسب‌دار یا بدون برچسب) با هم مقایسه کنید.

۵. کد بخش «پیاده‌سازی در پایتون» را اجرا کنید و به‌جای دو ویژگی «طول و عرض کاسبرگ»، «طول و عرض گلبرگ» را رسم کنید. آیا تفکیک سه گونه در این حالت بهتر است یا بدتر؟ چرا؟

فصل ۲

آشنایی با داده و پیش پردازش

اهداف این فصل

- شناخت انواع ویژگی‌ها و مقیاس‌های اندازه‌گیری داده
- درک مفهوم کیفیت داده و منابع اصلی مشکلات آن
- تسلط بر روش‌های پاک‌سازی، یکپارچه‌سازی، تبدیل و کاهش داده
- آشنایی با معیارهای شباهت و فاصله میان نمونه‌ها
- پیاده‌سازی عملی هر مرحله با پایتون و مشاهده اثر آن روی داده

۱.۲ انواع ویژگی‌ها

هر مجموعه داده از تعدادی نمونه^۱ تشکیل شده که هر یک با مجموعه‌ای از ویژگی‌ها^۲ توصیف می‌شود. شناخت دقیق نوع هر ویژگی، پیش‌نیاز انتخاب روش پیش‌پردازش و الگوریتم مناسب است. ویژگی‌ها را می‌توان از دو منظر دسته‌بندی کرد.

دسته‌بندی کیفی در برابر کمی

- ویژگی‌های کیفی^۳

Instance / Object / Record^۱

Attributes / Features^۲

Categorical / Qualitative^۳

– اسمی^۴: مقادیر فقط برچسب‌اند و ترتیب یا فاصله معناداری ندارند. مثال: رنگ چشم، شهر محل سکونت.

– ترتیبی^۵: مقادیر ترتیب معناداری دارند، اما فاصله میان آن‌ها مشخص یا یکسان نیست. مثال: سطح تحصیلات (دیپلم، کارشناسی، کارشناسی ارشد)، رضایت مشتری (کم، متوسط، زیاد).

• ویژگی‌های کمی^۶

– بازه‌ای^۷: فاصله میان مقادیر معنادار است، اما صفر مطلق ندارد. مثال: دما بر حسب سلسیوس.

– نسبی^۸: علاوه بر فاصله معنادار، صفر مطلق نیز دارد، بنابراین نسبت دو مقدار هم معنادار است. مثال: سن، درآمد، وزن.

هر نوع ویژگی مجموعه مشخصی از عملیات ریاضی معنادار را مجاز می‌کند؛ برای مثال میانگین‌گرفتن از «رنگ چشم» بی‌معناست، اما برای «سن» کاملاً معنادار است. جدول ۱.۲ این ارتباط را خلاصه می‌کند.

جدول ۱.۲: انواع ویژگی‌ها و عملیات معنادار برای هر نوع

نوع	ویژگی کلیدی	مثال	عملیات مجاز
اسمی	فقط برچسب، بدون ترتیب	رنگ چشم، کد شهر	برابری، مد
ترتیبی	دارای ترتیب، بدون فاصله معنادار	سطح تحصیلات، رتبه	مقایسه، میانه
بازه‌ای	فاصله معنادار، بدون صفر مطلق	دمای سلسیوس، سال تقویمی	جمع، میانگین، تفریق
نسبی	فاصله معنادار و صفر مطلق	سن، درآمد، وزن	همه عملیات، نسبت

Nominal^۴

Ordinal^۵

Numeric / Quantitative^۶

Interval^۷

Ratio^۸

دسته بندی گسسته در برابر پیوسته

از منظری دیگر، ویژگی ها به گسسته (تعداد محدود یا شمارش پذیر از مقادیر، مانند تعداد فرزندان) و پیوسته (بی نهایت مقدار ممکن در یک بازه، مانند قد یا وزن) تقسیم می شوند. تشخیص درست این نوع، در انتخاب روش گسسته سازی (بخش ۳.۲) و همچنین نوع نمودار مناسب برای تحلیل اکتشافی داده اهمیت دارد.

۲.۲ کیفیت داده

پیش از هر کاوشی، باید کیفیت داده ارزیابی شود. مهم ترین مشکلات رایج در داده های واقعی عبارت اند از:

- **مقادیر گم شده**^۹: به دلایلی مانند خطای ثبت، عدم پاسخ گویی کاربر یا خرابی حسگر.
- **نویز**^{۱۰}: خطای تصادفی یا انحراف در مقدار اندازه گیری شده.
- **داده های ناسازگار**^{۱۱}: تناقض میان رکوردها، مثلاً دو مقدار متفاوت برای سن یک فرد در دو جدول مختلف.
- **داده های تکراری**^{۱۲}: ثبت چندباره یک رکورد.
- **داده های پرت**^{۱۳}: مقادیری که به طور قابل توجهی با بقیه داده تفاوت دارند (جزئیات بیشتر در فصل ۸).

نکته مهم این است که نویز و داده پرت یکسان نیستند: نویز معمولاً خطای تصادفی و بی معنی است که باید حذف یا اصلاح شود، اما داده پرت می تواند خود هدف تحلیل باشد (مثلاً تراکنش متقلبانه).

اولین گام عملی در ارزیابی کیفیت، دیدن الگوی مقادیر گم شده است. شکل ۱.۲ نمونه ای از این نمودار را نشان می دهد: هر سطر یک رکورد، هر ستون یک ویژگی، و خانه های سفید نشان دهنده مقدار گم شده اند. در این مثال، ستون های «درآمد» و «امتیاز رضایت» بیشترین گمشدگی را دارند و ستون «شهر» تقریباً کامل است؛ چنین الگویی به تحلیلگر می گوید تلاش پاک سازی را روی کدام ستون ها متمرکز کند.


Missing Values^۹

Noise^{۱۰}

Inconsistent Data^{۱۱}

Duplicate Data^{۱۲}


Outliers^{۱۳}



شکل ۱۰۲: نمایش الگوی مقادیر گمشده در یک مجموعه داده (سفید = گمشده)

۳.۲ پیش پردازش داده

پیش پردازش داده مجموعه‌ای از گام‌های پشت‌سرهم است که داده خام را به داده‌ای مناسب برای الگوریتم‌های داده‌کاوی تبدیل می‌کند. شکل ۲.۲ ترتیب متداول این گام‌ها را نشان می‌دهد؛ هر یک در ادامه به تفصیل بررسی می‌شود.



شکل ۲.۲: گام‌های متداول پیش پردازش داده

پاک‌سازی داده

رایج‌ترین راهکارها برای مقادیر گمشده در جدول ۲.۲ آمده‌اند. انتخاب میان آن‌ها به مقدار گمشدگی، علت آن و اهمیت ستون بستگی دارد. برای هموارسازی نویز نیز روش‌هایی مانند بین‌بندی^{۱۴}، رگرسیون و تحلیل خوشه‌ای (برای شناسایی و حذف نقاط دورافتاده) به کار می‌روند.

^{۱۴}Binning

جدول ۲.۲: راهکارهای مواجهه با مقادیر گمشده

راهکار	مزیت	عیب
حذف رکورد	ساده و سریع	اتلاف داده؛ در گمشدگی زیاد خطرناک
جایگذاری میانگین/میانه/مد	با حفظ تعداد نمونه‌ها؛ پیاده‌سازی آسان	کاهش واریانس و نادیده گرفتن روابط میان ویژگی‌ها
جایگذاری با مدل پیش‌بینی	استفاده از سایر ویژگی‌ها؛ دقت بالاتر	پیچیده‌تر و مستعد نشت اطلاعات

نمونه‌کد زیر، شمارش مقادیر گمشده و جایگذاری آن‌ها با میانه را با `pandas` و `scikit-learn` نشان می‌دهد:

```
keywordstyle
```

```

dp sa sadnap tropmi | ۱
retupmIelpmiS tropmi etupmi.nraelks morf | ۲
| ۳
)"vsc.sremotsuc"(vsc_daer.dp = fd | ۴
| ۵
?nmuloc hcae ni gnissim era seulav ynam woh )1 # | ۶
))(mus.)(ansi.fd(tnirp | ۷
| ۸
naidem nmuloc eht htiw spag ciremun llif )2 # | ۹
snmuloc.)"rebmun"=edulcni(sepytd_tceles.fd = sloc_mun | ۱۰
)"naidem"=ygetarts(retupmIelpmiS = retupmi | ۱۱
)]sloc_mun[fd(mrofsnart_tif.retupmi = ]sloc_mun[fd | ۱۲

```

یکپارچه‌سازی داده

وقتی داده از چند منبع مختلف (مثلاً چند پایگاه داده یا چند فایل) جمع‌آوری می‌شود، باید به مسائلی مانند موارد زیر توجه کرد:

- تشخیص موجودیت یکسان^{۱۵}: آیا `customer_id` در یک جدول همان `cust_no` در جدول دیگر است؟

- **افزونگی**^{۱۶}: آیا یک ویژگی از ترکیب چند ویژگی دیگر قابل استخراج است؟ (مثلاً سود، از تفاضل درآمد و هزینه.)
- **تناقض مقیاس یا واحد**: مثلاً دما در یک منبع بر حسب سلسیوس و در منبع دیگر بر حسب فارنهایت ثبت شده باشد.

تبدیل و نرمال سازی داده

بسیاری از الگوریتم‌ها (به ویژه آن‌هایی که بر پایه فاصله عمل می‌کنند، مانند نزدیک‌ترین همسایه یا k-means) به مقیاس ویژگی‌ها حساس‌اند. اگر یک ویژگی در بازه $[0, 1]$ و ویژگی دیگر در بازه $[0, 100000]$ باشد، ویژگی دوم به‌طور نادرست بر محاسبه فاصله غالب می‌شود. دو روش رایج نرمال سازی عبارت‌اند از:

نرمال سازی Min-Max مقدار هر ویژگی به بازه $[0, 1]$ نگاشت می‌شود:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)}$$

استاندارد سازی Z-score مقدار هر ویژگی بر اساس میانگین (μ) و انحراف معیار (σ) آن تبدیل می‌شود:

$$x' = \frac{x - \mu}{\sigma}$$

استاندارد سازی Z-score معمولاً در حضور داده‌های پرت پایدارتر از Min-Max عمل می‌کند، زیرا Min-Max به شدت به مقادیر حداقل و حداکثر حساس است.


یک مثال عددی پنج مشاهده با مقادیر 10, 20, 30, 40, 100 را در نظر بگیرید (مقدار ۱۰۰ یک مقدار پرت نسبت به بقیه است). برای این داده $\min = 10$, $\max = 100$, $\mu = 40$ و $\sigma \approx 31.62$ (انحراف معیار جامعه) است. نتیجه دو تبدیل در جدول ۳.۲ آمده است. دقت کنید که در Min-Max مقدار پرت باعث می‌شود چهار مقدار دیگر در بازه باریک $[0, 0.33]$ فشرده شوند.

اهمیت مقیاس بندی را وقتی بهتر می‌بینیم که چند ویژگی با مقیاس‌های بسیار متفاوت داشته باشیم. شکل ۳.۲ دو خوشه مصنوعی از افراد را بر اساس «سن» (بازه چند ده) و «درآمد» (بازه ده‌ها هزار) نشان می‌دهد. در نمودار سمت چپ (مقیاس خام)، فاصله اقلیدسی عملاً فقط به درآمد وابسته است و سن هیچ نقشی ندارد؛ پس از هر دو نوع مقیاس بندی، دو ویژگی وزن قابل مقایسه‌ای پیدا می‌کنند.

پیاده سازی این دو تبدیل با scikit-learn به صورت زیر است:

جدول ۳.۲: مقایسه عددی نرمال سازی Min-Max و Z-score روی یک نمونه کوچک

ردیف	x	Min-Max	Z-score
۱	۱۰	۰۰۰.۰	-0.949
۲	۲۰	۱۱۱.۰	-0.632
۳	۳۰	۲۲۲.۰	-0.316
۴	۴۰	۳۳۳.۰	۰۰۰.۰
۵	۱۰۰	۰۰۰.۱	۱.۸۹۷



شکل ۳.۲: اثر مقیاس بندی بر دو ویژگی با مقیاس متفاوت: از چپ به راست، مقیاس خام، Min-Max و Z-score

```
keywordstyle
1 import numpy as np
2 from sklearn.preprocessing import MinMaxScaler,
  StandardScaler
3
4 x = np.array([[10], [20], [30], [40], [100]], dtype=float)
5
6 x_minmax = MinMaxScaler().fit_transform(x)
7 x_zscore = StandardScaler().fit_transform(x)
8
9 print(x_minmax.ravel().round(3)) # [0.    0.111 0.222
  0.333 1.    ]
10 print(x_zscore.ravel().round(3)) # [-0.949 -0.632 -0.316
  0.    1.897]
```

کاهش داده و کاهش ابعاد

هدف کاهش داده، رسیدن به بازنمایی کوچک تر اما تقریباً برابر از نظر محتوای اطلاعاتی است. دو رویکرد اصلی عبارتند از:

- کاهش تعداد نمونه‌ها: از طریق نمونه برداری^{۱۷} یا تجمیع داده.
- کاهش تعداد ویژگی‌ها (کاهش ابعاد): از طریق انتخاب زیرمجموعه‌ای از ویژگی‌ها^{۱۸} یا استخراج ویژگی جدید.

رایج ترین روش استخراج ویژگی، تحلیل مؤلفه‌های اصلی^{۱۹} است. ایده اصلی PCA یافتن جهت‌هایی (مؤلفه‌های اصلی) در فضای ویژگی‌هاست که بیشترین واریانس داده را حفظ می‌کنند؛ با تصویر کردن داده روی چند مؤلفه اول، می‌توان ابعاد را کاهش داد در حالی که بخش عمده اطلاعات داده حفظ می‌شود. توجه شود که PCA پیش از اجرا نیازمند استانداردسازی داده است، زیرا بر پایه واریانس عمل می‌کند. مراحل کلی PCA به صورت زیر است:

۱. استانداردسازی هر ویژگی (میانگین صفر و واریانس یک).
 ۲. محاسبه ماتریس کوواریانس ویژگی‌ها.
 ۳. یافتن بردارهای ویژه و مقادیر ویژه این ماتریس؛ بردار ویژه با بزرگترین مقدار ویژه، جهت بیشترین واریانس (مؤلفه اول) است.
 ۴. انتخاب k مؤلفه اول و تصویر کردن داده روی آن‌ها.
- مجموعه داده Iris چهار ویژگی دارد و نمی‌توان آن را مستقیماً روی صفحه رسم کرد. شکل ۴.۲ نتیجه کاهش آن به دو مؤلفه اصلی را نشان می‌دهد. دو مؤلفه اول در مجموع حدود ۹۶ درصد واریانس داده را نگه می‌دارند (۷۳ درصد و ۲۳ درصد)، و با وجود حذف دو بعد، سه گونه هنوز به خوبی قابل تشخیص‌اند.


keywordstyle

```
siri_daol tropmi stesatad.nraelks morf | ۱
relacSdradnatS tropmi gnissecorperp.nraelks morf | ۲
ACP tropmi noitisopmoted.nraelks morf | ۳
| ۴
atad.)(siri_daol = X | ۵
```

Sampling^{۱۷}

Feature Selection^{۱۸}

Principal Component Analysis (PCA)^{۱۹}



شکل ۴.۲: تصویر مجموعه داده Iris روی دو مؤلفه اصلی (کاهش از چهار بعد به دو بعد)

```

X(mrofsnart_tif.)(relacSdradnatS = delacs_X | ۶
    | ۷
    )2=stnenopmoc_n(ACP = acp | ۸
    )delacs_X(mrofsnart_tif.acp = d2_X | ۹
    | ۱۰
    037.0[ tuoba # )_oitar_ecnairav_denialpxe.acp(tnirp | ۱۱
    ]922.0 |
  
```


گسسته‌سازی و سلسله‌مراتب مفهومی

برخی الگوریتم‌ها (مانند نسخه‌های پایه درخت تصمیم یا بیز ساده) بهتر با داده‌های کیفی کار می‌کنند. **گسسته‌سازی** فرآیند تبدیل یک ویژگی عددی پیوسته به تعدادی بازه گسسته (مانند تبدیل سن به گروه‌های «جوان، میان‌سال، مسن») است. روش‌های رایج شامل بین‌بندی با عرض یکسان^{۲۰}، بین‌بندی با فراوانی یکسان^{۲۱} و روش‌های مبتنی بر خوشه‌بندی هستند. تفاوت این دو روش بین‌بندی در شکل ۵.۲ دیده می‌شود. در بین‌بندی با عرض یکسان، طول همه بازه‌ها برابر است اما تعداد رکوردها در آن‌ها یکسان نیست (وقتی داده چوله است، یک بازه

^{۲۰}Equal-width

^{۲۱}Equal-depth

ممکن است تقریباً خالی بماند). در بین بندی با فراوانی یکسان، هر بازه تعداد برابری رکورد دارد اما عرض بازه‌ها متفاوت است.



شکل ۵.۲: مقایسه بین بندی با عرض یکسان (چپ) و بین بندی با فراوانی یکسان (راست) روی ویژگی سن

```
keywordstyle
dp sa sadnap tropmi | ۱
| ۲
| ۳ [(seireS.dp = sega
| ۴
| ۵ )4=snib ,sega(tuc.dp = htdiw_lauqe
| ۶ htgne1
| ۷ )4=q ,sega(tucq.dp = htped_lauqe
| ۸ sdrocer
| ۹
| ۱۰ ))(xedni_tros.)(stnuoc_eulav.htdiw_lauqe(tnirp
| ۱۱ ))(xedni_tros.)(stnuoc_eulav.htped_lauqe(tnirp
```

سلسله مراتب مفهومی^{۲۲} نیز به تعریف سطوح مختلف انتزاع برای یک ویژگی اشاره دارد (مثلاً شهر → استان → کشور)، که در تحلیل های چندسطحی کاربرد دارد.

۴.۲ معیارهای شباهت و فاصله

بسیاری از الگوریتم های داده کاوی (خوشه بندی، نزدیک ترین همسایه، تشخیص داده پرت) بر پایه سنجش شباهت یا فاصله میان دو نمونه عمل می کنند. رایج ترین معیارها عبارت اند از:

^{۲۲} Concept Hierarchy


فاصله اقلیدسی برای دو بردار x و y در فضای n -بعدی:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

فاصله منهتن

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

تفاوت این دو فاصله را می توان روی صفحه دید. دو نقطه $A = (0, 0)$ و $B = (4, 3)$ را در نظر بگیرید. فاصله اقلیدسی طول پاره خط مستقیم میان آن هاست: $\sqrt{4^2 + 3^2} = 5$. فاصله منهتن مانند حرکت در خیابان های شبکه ای یک شهر است که فقط در امتداد افقی و عمودی می توان رفت: $4 + 3 = 7$ (شکل ۶.۲).



شکل ۶.۲: مقایسه فاصله اقلیدسی و فاصله منهتن میان دو نقطه در صفحه

فاصله مینکوفسکی تعمیمی از دو فاصله بالا با پارامتر p :

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{1/p}$$

که برای $p = 1$ به فاصله منهتن و برای $p = 2$ به فاصله اقلیدسی تبدیل می شود.

شباهت کسینوسی برای داده های با ابعاد بالا و پراکنده (مانند بردارهای متنی)، شباهت کسینوسی که زاویه میان دو بردار را می سنجد، اغلب مناسب تر از فاصله اقلیدسی است:

$$\text{sim}(x, y) = \frac{x \cdot y}{\|x\| \|y\|}$$

برای ویژگی‌های اسمی یا دودویی نیز معیارهایی مانند ضریب تطابق ساده^{۲۳} و ضریب ژاکارد^{۲۴} به کار می‌روند که در فصل مربوط به خوشه‌بندی (فصل ۷) دوباره به آن‌ها پرداخته می‌شود. جدول ۴.۲ چهار معیار اصلی این بخش را کنار هم قرار می‌دهد.

جدول ۴.۲: خلاصه معیارهای فاصله و شباهت

معیار	فرمول	کاربرد مناسب
اقلیدسی	$\sqrt{\sum_i (x_i - y_i)^2}$	داده‌های عددی با ابعاد کم و مقیاس یکسان
منهتن	$\sum_i x_i - y_i $	داده‌هایی که مقادیر پرت دارند یا ابعاد آن‌ها مستقل‌اند
مینکوفسکی	$(\sum_i x_i - y_i ^p)^{1/p}$	تعمیم دو معیار بالا؛ پارامتر p قابل تنظیم
کسینوسی	$\frac{x \cdot y}{\ x\ \ y\ }$	داده‌های پراکنده و پرابعاد مانند متن

محاسبه این معیارها با `scipy` کوتاه است. برای دو نقطه شکل ۶.۲:

```
keywordstyle
1 from scipy.spatial import distance
2
3 A, B = [0, 0], [4, 3]
4
5 print(distance.euclidean(A, B))    # 5.0
6 print(distance.cityblock(A, B))    # 7    (Manhattan)
7 print(distance.minkowski(A, B, p=3))
8
9 # cosine * distance = 1 - cosine similarity
10 print(1 - distance.cosine([1, 2, 3], [2, 4, 6])) # 1.0
```

پیاده‌سازی در پایتون

نمونه‌کدهای این فصل در متن هر بخش آمده‌اند. مجموعه کامل آن‌ها به صورت یک اسکرپت واحد (جایگذاری، مقیاس‌بندی، PCA، بین‌بندی و محاسبه فاصله) در بخش «فصل ۲» پیوست الف (آ) گردآوری شده است.

^{۲۳} Simple Matching Coefficient
^{۲۴} Jaccard Coefficient

خلاصه فصل

در این فصل با انواع ویژگی‌ها، منابع اصلی مشکلات کیفیت داده، و مراحل کلیدی پیش‌پردازش شامل پاک‌سازی، یکپارچه‌سازی، تبدیل، کاهش داده و گسسته‌سازی آشنا شدیم. همچنین رایج‌ترین معیارهای فاصله و شباهت را که در فصل‌های بعدی (به‌ویژه طبقه‌بندی و خوشه‌بندی) بارها استفاده خواهند شد، مرور کردیم. در فصل بعد، به اولین وظیفه اصلی داده‌کاوی یعنی طبقه‌بندی می‌پردازیم.

تمرین‌ها

۱. برای هر یک از ویژگی‌های «شماره ملی»، «دمای بدن»، «رتبه مسابقه» و «تعداد فرزندان» نوع آن (اسمی/ترتیبی/بازه‌ای/نسبتی) را مشخص کنید.
۲. فرض کنید در یک مجموعه داده، ۱۵ درصد مقادیر ستون «درآمد» گم شده است. با توجه به جدول ۲.۲، دو راهکار پیشنهاد دهید و مزایا و معایب هر کدام را توضیح دهید.
۳. مقادیر 5, 15, 25, 35, 500 را هم با Min-Max و هم با Z-score تبدیل کنید و نتیجه را با جدول ۳.۲ مقایسه کنید. کدام روش در برابر مقدار ۵۰۰ پایدارتر است؟
۴. فاصله اقلیدسی و فاصله منهن را برای دو بردار $x = (2, 4, 6)$ و $y = (5, 1, 8)$ محاسبه کنید و پاسخ را با کد `scipy` بررسی کنید.
۵. چرا شباهت کسینوسی برای مقایسه اسناد متنی معمولاً بهتر از فاصله اقلیدسی عمل می‌کند؟
۶. در شکل ۴.۲، اگر فقط مؤلفه اول را نگه می‌داشتیم، تفکیک کدام دو گونه دشوارتر می‌شد؟ چرا؟
۷. با `pd.cut` و `pd.qcut` یک ستون سن دلخواه را بین‌بندی کنید و تفاوت تعداد رکوردها در بازه‌ها را با شکل ۵.۲ مقایسه کنید.

بخش دوم

یادگیری با نظارت

فصل ۳

طبقه‌بندی: مفاهیم پایه

اهداف این فصل

- درک مفهوم یادگیری با نظارت و مسئله طبقه‌بندی
- یادگیری نحوه ساخت درخت تصمیم و معیارهای انتخاب ویژگی
- آشنایی با هرس درخت تصمیم برای جلوگیری از بیش‌برازش
- یادگیری طبقه‌بند بیز ساده
- آشنایی مقدماتی با ماتریس درهم‌ریختگی و معیار دقت

۱.۳ مقدمه‌ای بر طبقه‌بندی

طبقه‌بندی^۱ یکی از رایج‌ترین وظایف یادگیری با نظارت^۲ است. در این نوع یادگیری، برخلاف خوشه‌بندی که در فصل ۷ خواهیم دید، مجموعه‌ای از نمونه‌های برچسب‌دار^۳ در اختیار داریم؛ یعنی برای هر نمونه، علاوه بر ویژگی‌های ورودی، مقدار کلاس هدف نیز مشخص است. هدف طبقه‌بندی، یادگیری یک تابع $f: X \rightarrow Y$ است که بتواند برای نمونه‌های جدید و دیده‌نشده، مقدار کلاس Y را از روی ویژگی‌های X پیش‌بینی کند.

Classification^۱
Supervised Learning^۲
Labeled Data^۳

مثال‌های رایج طبقه‌بندی عبارت‌اند از: تشخیص اسپم بودن یک ایمیل (بله/خیر)، پیش‌بینی نکول وام یک متقاضی (پرداخت/نکول)، و تشخیص نوع گل بر اساس اندازه گلبرگ‌ها (مجموعه داده معروف Iris).
فرآیند کلی ساخت یک مدل طبقه‌بندی دو مرحله دارد:

۱. **مرحله آموزش**^۴: مدل با استفاده از مجموعه آموزش^۵ که شامل نمونه‌های برچسب‌دار است، الگوی رابطه میان ویژگی‌ها و کلاس را یاد می‌گیرد.
۲. **مرحله آزمون**^۶: عملکرد مدل روی مجموعه‌ای جداگانه به نام مجموعه آزمون^۷ که در آموزش دیده نشده، سنجیده می‌شود تا از توانایی تعمیم^۸ مدل مطمئن شویم.

۲.۳ درخت تصمیم

درخت تصمیم^۹ یکی از قابل‌فهم‌ترین و پرکاربردترین الگوریتم‌های طبقه‌بندی است. ساختار آن شبیه یک فلوچارت است: هر گره داخلی یک آزمون روی یک ویژگی است، هر شاخه نتیجه آن آزمون را نشان می‌دهد و هر برگ^{۱۰} یک برچسب کلاس است. مزیت اصلی درخت تصمیم، تفسیرپذیری بالای آن است؛ می‌توان مسیر از ریشه تا هر برگ را به صورت یک قانون IF-THEN ساده خواند. سؤال اصلی در ساخت درخت تصمیم این است: در هر گره، کدام ویژگی برای تقسیم داده انتخاب شود؟ پاسخ به این سؤال با معیارهای زیر داده می‌شود.

معیارهای انتخاب ویژگی

آنتروپی و بهره اطلاعاتی بهره اطلاعاتی^{۱۱} معیاری است که در الگوریتم ID^۳ استفاده می‌شود و بر پایه مفهوم آنتروپی از نظریه اطلاعات ساخته شده است. برای یک مجموعه داده D با m کلاس، آنتروپی به صورت زیر تعریف می‌شود:

$$\text{Entropy}(D) = - \sum_{i=1}^m p_i \log_2(p_i)$$

Training^۴
Training Set^۵
Testing^۶
Test Set^۷
Generalization^۸
Decision Tree^۹
Leaf^{۱۰}
Information Gain^{۱۱}

که در آن p_i نسبت نمونه‌های کلاس i در D است. آنتروپی معیاری از «ناخالصی» یا عدم قطعیت مجموعه داده است: هرچه کلاس‌ها یکنواخت‌تر توزیع شده باشند، آنتروپی بیشتر است؛ اگر همه نمونه‌ها به یک کلاس تعلق داشته باشند، آنتروپی برابر صفر است. پس از تقسیم داده بر اساس ویژگی A به زیرمجموعه‌های $D_1, \dots, D_v$ ، بهره اطلاعاتی به‌صورت کاهش آنتروپی تعریف می‌شود:

$$\text{Gain}(D, A) = \text{Entropy}(D) - \sum_{j=1}^v \frac{|D_j|}{|D|} \text{Entropy}(D_j)$$

در هر گره، ویژگی‌ای انتخاب می‌شود که بیشترین بهره اطلاعاتی را دارد.

نسبت بهره یک ضعف بهره اطلاعاتی این است که به‌طور طبیعی به ویژگی‌هایی با تعداد مقادیر زیاد (مانند شناسه مشتری) گرایش پیدا می‌کند، حتی اگر آن ویژگی از نظر پیش‌بینی بی‌ارزش باشد. الگوریتم $C4.5$ برای رفع این مشکل، معیار **نسبت بهره**^{۱۲} را معرفی کرد که بهره اطلاعاتی را بر یک عامل نرمال‌ساز به نام اطلاعات تقسیم^{۱۳} تقسیم می‌کند:

$$\text{GainRatio}(D, A) = \frac{\text{Gain}(D, A)}{\text{SplitInfo}(D, A)}$$

شاخص جینی شاخص جینی^{۱۴} معیاری است که در الگوریتم CART استفاده می‌شود و احتمال طبقه‌بندی نادرست یک نمونه تصادفی را می‌سنجد:

$$\text{Gini}(D) = 1 - \sum_{i=1}^m p_i^2$$

مشابه آنتروپی، هرچه شاخص جینی کوچک‌تر باشد، مجموعه خالص‌تر است. در هر گره، ویژگی‌ای انتخاب می‌شود که بیشترین کاهش شاخص جینی را ایجاد کند.

هرس درخت تصمیم

اگر اجازه داده شود درخت تا رسیدن به خلوص کامل هر برگ رشد کند، مدل به جزئیات و نویز داده‌های آموزش بیش از حد وابسته می‌شود؛ پدیده‌ای که **بیش‌برازش**^{۱۵} نام دارد و باعث افت

^{۱۲} Gain Ratio
^{۱۳} Split Information
^{۱۴} Gini Index
^{۱۵} Overfitting

عملکرد روی داده‌های جدید می‌شود. هرس^{۱۶} تکنیکی برای مقابله با این مشکل است و به دو صورت انجام می‌شود:

- هرس پیشین^{۱۷}: رشد درخت زودتر متوقف می‌شود، مثلاً با تعیین حداکثر عمق درخت یا حداقل تعداد نمونه در هر برگ.
 - هرس پسین^{۱۸}: ابتدا اجازه داده می‌شود درخت کامل رشد کند، سپس شاخه‌هایی که تأثیر چندانی بر دقت روی داده اعتبارسنجی^{۱۹} ندارند، حذف می‌شوند.
- در عمل، هرس پسین معمولاً نتایج بهتری می‌دهد، هرچند از نظر محاسباتی پرهزینه‌تر است.

۳.۳ طبقه‌بند بیز ساده

طبقه‌بند بیز ساده^{۲۰} روشی احتمالاتی برای طبقه‌بندی است که بر پایه قضیه بیز عمل می‌کند:

$$P(C | X) = \frac{P(X | C) P(C)}{P(X)}$$

که در آن C کلاس هدف و $X = (x_1, x_2, \dots, x_n)$ بردار ویژگی‌های یک نمونه است. هدف، یافتن کلاسی است که $P(C | X)$ را بیشینه می‌کند. نام «ساده» (Naive) به این دلیل است که این روش فرض می‌کند ویژگی‌ها، مشروط بر کلاس، از یکدیگر مستقل هستند. با این فرض:

$$P(X | C) = \prod_{i=1}^n P(x_i | C)$$

با وجود ساده‌بودن (و اغلب نادرست‌بودن) این فرض استقلال در دنیای واقعی، بیز ساده در عمل، به‌ویژه در طبقه‌بندی متن (مانند تشخیص اسپم)، عملکرد شگفت‌آور خوبی دارد و از نظر محاسباتی بسیار کارآمد است، چون نیازی به یادگیری روابط پیچیده میان ویژگی‌ها ندارد.

Pruning^{۱۶}

Pre-pruning^{۱۷}

Post-pruning^{۱۸}

Validation Set^{۱۹}

Naive Bayes^{۲۰}

مسئله احتمال صفر و هموارسازی لاپلاس اگر یک مقدار ویژگی در داده آموزش هرگز با یک کلاس خاص هم‌رخداد نداشته باشد، $P(x_i | C)$ برابر صفر محاسبه می‌شود و کل حاصل ضرب را صفر می‌کند، حتی اگر سایر ویژگی‌ها به شدت بر آن کلاس دلالت کنند. برای رفع این مشکل، از هموارسازی لاپلاس^{۲۱} استفاده می‌شود که یک مقدار کوچک به همه شمارش‌ها اضافه می‌کند تا هیچ احتمالی دقیقاً صفر نشود.

۴.۳ ارزیابی مقدماتی

پس از آموزش یک مدل طبقه‌بندی، باید عملکرد آن را روی داده آزمون بسنجیم. ابزار پایه برای این کار ماتریس درهم‌ریختگی^{۲۲} است که برای یک مسئله دوکلاسه به شکل زیر است:

پیش‌بینی: مثبت		پیش‌بینی: منفی
واقعی: مثبت	True Positive (TP)	False Negative (FN)
واقعی: منفی	False Positive (FP)	True Negative (TN)

ساده‌ترین معیار برخاسته از این ماتریس، دقت کلی^{۲۳} است:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

هرچند دقت کلی معیاری شهودی است، اما در مسائلی که کلاس‌ها نامتوازن‌اند (مثلاً تشخیص تقلب که تنها ۱ درصد تراکنش‌ها متقلبانه‌اند) می‌تواند گمراه‌کننده باشد؛ مدلی که همیشه «غیرمتقلبانه» پیش‌بینی کند، دقت ۹۹ درصد دارد اما کاملاً بی‌فایده است. معیارهای دقیق‌تر مانند Precision، Recall و F1-Score، که این مشکل را برطرف می‌کنند، در فصل ۴ به‌طور کامل بررسی خواهند شد.

پیاده‌سازی در پایتون

پیاده‌سازی درخت تصمیم (DecisionTreeClassifier) با معیارهای entropy و gini، و همچنین طبقه‌بند GaussianNB، به‌همراه رسم ماتریس درهم‌ریختگی، در بخش «فصل ۳» پیوست الف (آ) آمده است.

^{۲۱}Laplace Smoothing

^{۲۲}Confusion Matrix

^{۲۳}Accuracy

خلاصه فصل

در این فصل با مفهوم یادگیری با نظارت و طبقه‌بندی آشنا شدیم. درخت تصمیم را به عنوان یک مدل قابل تفسیر بررسی کردیم و سه معیار اصلی انتخاب ویژگی (بهره اطلاعاتی، نسبت بهره و شاخص جینی) و همچنین اهمیت هرس برای جلوگیری از بیش‌برازش را دیدیم. سپس طبقه‌بند بیز ساده را به عنوان یک روش احتمالاتی و کارآمد معرفی کردیم. در پایان، با ماتریس درهم‌ریختگی و معیار دقت، اولین ابزار ارزیابی مدل را آموختیم. در فصل بعد، به سراغ الگوریتم‌های پیشرفته‌تر طبقه‌بندی (نزدیک‌ترین همسایه، ماشین بردار پشتیبان، روش‌های ترکیبی) و معیارهای ارزیابی دقیق‌تر می‌رویم.

تمرین‌ها

۱. آنتروپی یک مجموعه داده با ۱۰ نمونه که ۶ نمونه از کلاس مثبت و ۴ نمونه از کلاس منفی هستند را محاسبه کنید.
۲. چرا معیار بهره اطلاعاتی به تنهایی می‌تواند به ویژگی‌هایی با مقادیر بسیار زیاد (مانند شناسه یکتای مشتری) گرایش پیدا کند؟ نسبت بهره چگونه این مشکل را حل می‌کند؟
۳. تفاوت هرس پیشین و هرس پسین را از نظر هزینه محاسباتی و کیفیت نتیجه نهایی مقایسه کنید.
۴. فرض استقلال شرطی در بیز ساده را با یک مثال نقض کنید (یعنی مثالی از دو ویژگی که مستقل از هم نیستند) و توضیح دهید چرا با وجود این نقض، مدل همچنان می‌تواند عملکرد قابل قبولی داشته باشد.
۵. برای یک مسئله تشخیص بیماری نادر که تنها ۲ درصد جمعیت به آن مبتلا هستند، توضیح دهید چرا دقت کلی به تنهایی معیار مناسبی برای ارزیابی مدل نیست.

فصل ۴

طبقه‌بندی پیشرفته و ارزیابی مدل

اهداف این فصل

- آشنایی با k نزدیک‌ترین همسایه (k -NN) و ماشین بردار پشتیبان (SVM)
- یادگیری روش‌های ارکستراسیون: Forest Random Boosting، Bagging،
- تسلط بر معیارهای ارزیابی: ROC/AUC F_1 ، Recall، Precision،

۱.۴ k نزدیک‌ترین همسایه (k -NN)

۲.۴ ماشین بردار پشتیبان (SVM)

۳.۴ روش‌های ترکیبی (Ensemble)

Forest Random و Bagging
Boosting

۴.۴ ارزیابی مدل

اعتبارسنجی متقاطع (Cross-Validation)

F1-Score Recall، Precision،

منحنی ROC و AUC

مسئله عدم توازن کلاس‌ها (Class Imbalance)

پیاده‌سازی در پایتون

پیاده‌سازی k -NN، SVM و Forest Random با scikit-learn در پیوست الف (آ).

تمرین‌ها

فصل ۵

مقدمه‌ای بر رگرسیون

اهداف این فصل

- درک تفاوت رگرسیون با طبقه‌بندی
- یادگیری رگرسیون خطی ساده و چندگانه
- آشنایی با رگرسیون لجستیک به عنوان پل میان رگرسیون و طبقه‌بندی
- آشنایی با معیارهای ارزیابی مدل‌های رگرسیون

۱.۵ رگرسیون در برابر طبقه‌بندی

در دو فصل قبل، با طبقه‌بندی آشنا شدیم که در آن متغیر هدف کیفی یا گسسته است (مثلاً «اسپم» یا «غیراسپم»). رگرسیون^۱ نیز مانند طبقه‌بندی یک وظیفه یادگیری با نظارت است، با این تفاوت اساسی که متغیر هدف در آن عددی و پیوسته است — مانند پیش‌بینی قیمت یک خانه، دمای فردا، یا میزان فروش ماه آینده. بسیاری از مفاهیمی که در فصل‌های قبل دیدیم (تفکیک آموزش/آزمون، اعتبارسنجی متقاطع، خطر بیش‌برازش) بدون تغییر برای رگرسیون نیز صادق‌اند؛ آنچه تغییر می‌کند، نوع مدل و معیار ارزیابی است.

^۱Regression

۲.۵ رگرسیون خطی ساده و چندگانه

رگرسیون خطی ساده^۲ رابطه میان یک متغیر مستقل x و یک متغیر هدف y را با یک خط راست مدل می‌کند:

$$\hat{y} = \beta_0 + \beta_1 x$$

که در آن β_0 عرض از مبدأ و β_1 شیب خط است. این ضرایب معمولاً با روش کمترین مربعات^۳ تخمین زده می‌شوند؛ یعنی مقادیری برای β_0 و β_1 انتخاب می‌شوند که مجموع مربعات خطای پیش‌بینی (فاصله عمودی هر نقطه داده تا خط برازش شده) را کمینه کنند. وقتی بیش از یک ویژگی ورودی داشته باشیم، از رگرسیون خطی چندگانه^۴ استفاده می‌شود که رابطه را به صورت زیر تعمیم می‌دهد:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

نکته مهم در رگرسیون چندگانه، توجه به هم‌خطی چندگانه^۵ است: اگر دو یا چند ویژگی ورودی به شدت با یکدیگر همبسته باشند، تفسیر ضرایب مدل دشوار و ناپایدار می‌شود، هرچند ممکن است دقت پیش‌بینی کلی مدل تحت تأثیر جدی قرار نگیرد.

۳.۵ رگرسیون لجستیک

با وجود نامش، رگرسیون لجستیک^۶ عملاً یک الگوریتم طبقه‌بندی است، نه رگرسیون به معنای پیش‌بینی یک مقدار پیوسته؛ این عنوان از تاریخچه توسعه روش باقی مانده است. رگرسیون لجستیک برای مسائل طبقه‌بندی دو کلاسه به کار می‌رود و به جای پیش‌بینی مستقیم کلاس، احتمال تعلق به کلاس مثبت را تخمین می‌زند. ایده اصلی این است که به جای برازش یک خط راست (که می‌تواند مقادیری خارج از بازه $[0, 1]$ تولید کند و برای احتمال بی‌معنی است)، از تابع سیگموئید^۷ برای نگاشت خروجی مدل خطی به بازه $[0, 1]$ استفاده می‌شود:

$$P(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}}$$

در نهایت، با مقایسه این احتمال با یک آستانه (معمولاً ۰.۵)، تصمیم نهایی کلاس گرفته می‌شود. به همین دلیل، رگرسیون لجستیک را می‌توان پلی میان مباحث این فصل و مباحث

Simple Linear Regression^۲
 Ordinary Least Squares (OLS)^۳
 Multiple Linear Regression^۴
 Multicollinearity^۵
 Logistic Regression^۶
 Sigmoid Function^۷

طبقه‌بندی فصل‌های قبل دانست، و از تمام معیارهای ارزیابی طبقه‌بندی (ماتریس درهم‌ریختگی، دقت مثبت، فراخوانی، منحنی ROC) که در فصل ۴ دیدیم، برای آن نیز استفاده می‌شود.

۴.۵ ارزیابی مدل‌های رگرسیون

از آنجا که خروجی رگرسیون عددی پیوسته است، معیارهای مبتنی بر ماتریس درهم‌ریختگی (که برای کلاس‌های گسسته تعریف شده‌اند) در اینجا کاربرد ندارند. به جای آن، معیارهای زیر بر پایه فاصله میان مقدار پیش‌بینی شده $\hat{y}_i$ و مقدار واقعی y_i تعریف می‌شوند.

میانگین مربعات خطا میانگین مربعات خطا^۸ مجذور تفاضل پیش‌بینی و مقدار واقعی است:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

به دلیل به توان دو رساندن خطا، این معیار به خطاهای بزرگ (نقاط پرت) حساسیت بیشتری نسبت به خطاهای کوچک نشان می‌دهد.

جذر میانگین مربعات خطا جذر میانگین مربعات خطا^۹ با گرفتن جذر از MSE به دست می‌آید:

$$RMSE = \sqrt{MSE}$$

مزیت اصلی RMSE نسبت به MSE این است که واحد آن با واحد متغیر هدف یکسان است (مثلاً اگر هدف قیمت به تومان باشد، RMSE نیز بر حسب تومان قابل تفسیر است)، در حالی که واحد MSE مجذور واحد اصلی است.

ضریب تعیین ضریب تعیین^{۱۰} نشان می‌دهد چه نسبتی از واریانس متغیر هدف توسط مدل توضیح داده می‌شود:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

که در آن $\bar{y}$ میانگین مقادیر واقعی است. مقدار R^2 نزدیک به ۱ نشان‌دهنده برازش خوب مدل و مقدار نزدیک به صفر (یا حتی منفی) نشان‌دهنده عملکرد ضعیف آن است.

Mean Squared Error (MSE)^۸

Root Mean Squared Error (RMSE)^۹

Coefficient of Determination R^2 (^{۱۰})

پیاده‌سازی در پایتون

پیاده‌سازی `LinearRegression` و `LogisticRegression` از `scikit-learn`، به همراه محاسبه `mean_squared_error` و `r2_score`، در بخش «فصل ۵» پیوست الف (آ) آمده است.

خلاصه فصل

در این فصل با رگرسیون به عنوان دومین وظیفه اصلی یادگیری با نظارت — این بار برای پیش‌بینی مقادیر پیوسته — آشنا شدیم. رگرسیون خطی ساده و چندگانه را با روش کمترین مربعات بررسی کردیم، رگرسیون لجستیک را به عنوان پلی میان رگرسیون و طبقه‌بندی معرفی کردیم، و در پایان با معیارهای ارزیابی مخصوص مسائل رگرسیون (R^2 ، RMSE، MSE) آشنا شدیم. با این فصل، بخش یادگیری با نظارت این کتاب به پایان می‌رسد. در فصل بعد، به دنیای یادگیری بدون نظارت و اولین موضوع آن، یعنی قوانین انجمنی، وارد می‌شویم.

تمرین‌ها

۱. توضیح دهید چرا رگرسیون لجستیک، با وجود نامش، در دسته الگوریتم‌های طبقه‌بندی قرار می‌گیرد نه رگرسیون.
۲. فرض کنید یک مدل رگرسیون خطی برای پیش‌بینی قیمت خانه دارید که دو ویژگی ورودی «متراژ» و «تعداد اتاق» به شدت با هم همبسته‌اند. مشکل احتمالی این وضعیت را توضیح دهید.
۳. چرا معیار RMSE برای گزارش نتیجه به یک ذی‌نفع غیرفنی معمولاً مناسب‌تر از MSE است؟
۴. اگر یک مدل رگرسیون مقدار $R^2 = 0.85$ داشته باشد، این عدد را به زبان ساده برای یک مدیر کسب‌وکار توضیح دهید.
۵. تابع سیگموید را رسم کنید (روی کاغذ یا با پایتون) و توضیح دهید چرا برای تبدیل خروجی یک مدل خطی به احتمال مناسب است.

بخش سوم
یادگیری بدون نظارت

فصل ۶

قوانین انجمنی

اهداف این فصل

- درک مفهوم قوانین انجمنی و کاربرد آن در تحلیل سبد خرید
- تسلط بر معیارهای Lift و Confidence Support
- یادگیری الگوریتم Apriori برای یافتن مجموعه‌های پرتکرار
- آشنایی با FP-Growth به عنوان روشی کارآمدتر

۱.۶ مقدمه: از یادگیری با نظارت به بدون نظارت

در چهار فصل گذشته، با وظایف یادگیری با نظارت (طبقه‌بندی و رگرسیون) آشنا شدیم که در آن‌ها داده برچسب‌دار بود. از این فصل به بعد، وارد دنیای یادگیری بدون نظارت^۱ می‌شویم، جایی که هیچ برچسب از پیش تعیین‌شده‌ای وجود ندارد و هدف، کشف ساختار یا الگوهای پنهان در خود داده است.

قوانین انجمنی^۲ یکی از قدیمی‌ترین و شناخته‌شده‌ترین وظایف یادگیری بدون نظارت است. مثال کلاسیک آن تحلیل سبد خرید^۳ است: با بررسی میلیون‌ها رسید خرید یک فروشگاه، آیا می‌توان الگوهایی مانند «مشریانی که نان و کره می‌خرند، با احتمال بالا شیر هم می‌خرند» را به صورت خودکار کشف کرد؟ چنین دانشی می‌تواند در چیدمان قفسه‌ها، طراحی تخفیف‌های ترکیبی و سیستم‌های پیشنهاددهنده استفاده شود.

^۱Unsupervised Learning

^۲Association Rules

^۳Market Basket Analysis

۲.۶ مفاهیم پایه

فرض کنید $I = \{i_1, i_2, \dots, i_m\}$ مجموعه همه کالاهای موجود در یک فروشگاه باشد و هر تراکنش T ^۴ زیرمجموعه‌ای از I باشد (یعنی سبد خرید یک مشتری). یک **قانون انجمنی**^۵ به صورت $A \Rightarrow B$ نوشته می‌شود، که در آن A و B دو مجموعه کالای مجزا از هم هستند (مثلاً $A = \{\text{نان}\}$ ، $B = \{\text{شیر}\}$).

سه معیار زیر برای سنجش کیفیت یک قانون انجمنی به کار می‌روند:

پشتیبانی پشتیبانی^۶ نشان می‌دهد چه نسبتی از کل تراکنش‌ها شامل هر دو مجموعه A و B با هم هستند:

$$\text{Support}(A \Rightarrow B) = \frac{|\{T : A \cup B \subseteq T\}|}{|\text{کل تراکنش‌ها}|}$$

پشتیبانی نشان‌دهنده شیوع یک الگو در کل داده است؛ قاعده‌ای با پشتیبانی بسیار کم، حتی اگر جالب باشد، ممکن است از نظر تجاری اهمیت کمی داشته باشد چون به ندرت رخ می‌دهد.

اطمینان اطمینان^۷ نشان می‌دهد از میان تراکنش‌هایی که A در آن‌ها وجود دارد، چه نسبتی B را نیز شامل می‌شوند:

$$\text{Confidence}(A \Rightarrow B) = \frac{\text{Support}(A \cup B)}{\text{Support}(A)}$$

اطمینان معادل احتمال شرطی $P(B | A)$ است.

لیفت مشکل اطمینان این است که اگر B در بین همه تراکنش‌ها بسیار رایج باشد (مثلاً اکثر مشتریان به هر حال نان می‌خرند)، اطمینان بالا می‌تواند گمراه‌کننده باشد و نشان‌دهنده یک رابطه واقعی نباشد. برای رفع این مشکل، از معیار لیفت^۸ استفاده می‌شود:

$$\text{Lift}(A \Rightarrow B) = \frac{\text{Confidence}(A \Rightarrow B)}{\text{Support}(B)}$$

اگر $\text{Lift} > 1$ ، حضور A احتمال حضور B را افزایش می‌دهد (رابطه مثبت). اگر $\text{Lift} \approx 1$ ، دو رویداد تقریباً مستقل‌اند (اطمینان بالا صرفاً به دلیل رواج بالای B بوده، نه یک رابطه واقعی). اگر $\text{Lift} < 1$ ، حضور A احتمال حضور B را کاهش می‌دهد (رابطه منفی).

^۴ Transaction

^۵ Association Rule

^۶ Support

^۷ Confidence

^۸ Lift

۳.۶ الگوریتم Apriori

چالش اصلی در یافتن قوانین انجمنی، تعداد نمایی زیرمجموعه‌های ممکن از کالاهاست: برای n کالا، 2^n زیرمجموعه ممکن وجود دارد که بررسی همه آن‌ها برای مجموعه داده‌های واقعی (با هزاران کالا) از نظر محاسباتی غیرممکن است. الگوریتم Apriori^۹ با استفاده از یک ویژگی هوشمندانه به نام اصل Apriori^{۱۰} این فضای جستجو را به شدت کاهش می‌دهد:

اگر یک مجموعه کالا پرتکرار^{۱۱} نباشد، هیچ‌یک از ابرمجموعه‌های آن نیز نمی‌توانند پرتکرار باشند.

به بیان دیگر، اگر مجموعه {نان، کره} پشتیبانی کافی نداشته باشد، نیازی به بررسی {نان، کره، شیر} نیست، چون پشتیبانی آن هرگز نمی‌تواند از پشتیبانی زیرمجموعه‌اش بیشتر باشد.

تولید مجموعه‌های پرتکرار

الگوریتم Apriori به صورت تکرارشونده و لایه‌به‌لایه عمل می‌کند:

۱. ابتدا پشتیبانی همه مجموعه‌های تک‌عضوی محاسبه می‌شود و آن‌هایی که از یک آستانه حداقلی^{۱۲} پایین‌ترند، حذف می‌شوند.
۲. از ترکیب مجموعه‌های پرتکرار باقی‌مانده، مجموعه‌های دو‌عضوی کاندیدا ساخته می‌شوند و دوباره پشتیبانی آن‌ها بررسی می‌شود.
۳. این فرآیند برای مجموعه‌های سه‌عضوی، چهارعضوی و به همین ترتیب ادامه می‌یابد تا مجموعه کاندیدای جدیدی باقی نماند.

استخراج قوانین

پس از یافتن همه مجموعه‌های پرتکرار، برای هر مجموعه، تمام تفکیک‌های ممکن آن به دو بخش A و B بررسی می‌شود و اطمینان هر قانون محاسبه می‌گردد. قوانینی که اطمینان آن‌ها از یک آستانه حداقلی^{۱۳} بیشتر باشد، به عنوان قوانین نهایی گزارش می‌شوند.

Apriori Algorithm^۹

Apriori Principle^{۱۰}

Frequent^{۱۱}

Minimum Support^{۱۲}

Minimum Confidence^{۱۳}

ضعف اصلی Apriori ضعف عملی این الگوریتم، نیاز به بارها اسکن کردن کل مجموعه داده (یک بار به ازای هر سطح از اندازه مجموعه کاندیدا) است که برای داده‌های بسیار بزرگ، هزینه زمانی و حافظه‌ای بالایی دارد.

۴.۶ الگوریتم FP-Growth

الگوریتم FP-Growth^{۱۴} برای رفع ضعف اصلی Apriori طراحی شده است. ایده اصلی آن، فشردن سازی کل مجموعه داده در یک ساختار درختی به نام **درخت FP**^{۱۵} است، به گونه‌ای که تنها با دو بار اسکن کل داده (به جای اسکن‌های مکرر، Apriori) می‌توان همه مجموعه‌های پرتکرار را با پیمایش این درخت استخراج کرد. به همین دلیل، FP-Growth در عمل معمولاً به مراتب سریع‌تر از Apriori است، هرچند پیاده‌سازی آن پیچیده‌تر است. برای اهداف آموزشی این کتاب، درک اصل Apriori اولویت دارد؛ FP-Growth را می‌توان نسخه بهینه‌شده همان ایده در نظر گرفت.

۵.۶ ارزیابی و انتخاب قوانین جالب

الگوریتم‌های یافتن قوانین انجمنی معمولاً تعداد بسیار زیادی قانون تولید می‌کنند که اغلب آن‌ها بی‌فایده یا بدیهی‌اند (مانند «مشتریانی که نان می‌خرند، احتمالاً نان می‌خواهند»). برای انتخاب قوانین واقعاً **جالب**^{۱۶}، معیار لیفت (که پیش‌تر دیدیم) نقش کلیدی دارد؛ قوانینی با لیفت نزدیک به ۱ معمولاً کنار گذاشته می‌شوند، حتی اگر پشتیبانی و اطمینان بالایی داشته باشند. علاوه بر این، قضاوت متخصص حوزه (مثلاً یک کارشناس بازاریابی که می‌داند کدام رابطه از قبل شناخته‌شده و کدام واقعاً جدید است) نقش تکمیلی مهمی در فیلتر نهایی قوانین ایفا می‌کند.

پیاده‌سازی در پایتون

پیاده‌سازی الگوریتم Apriori و استخراج قوانین با کتابخانه `mlxtend` (توابع `apriori` و `association_rules`) در بخش «فصل ۶» پیوست الف (آ) آمده است.

^{۱۴}Frequent Pattern Growth

^{۱۵}FP-Tree

^{۱۶}Interesting

خلاصه فصل

در این فصل، اولین وظیفه یادگیری بدون نظارت این کتاب، یعنی قوانین انجمنی، را بررسی کردیم. با سه معیار کلیدی — پشتیبانی، اطمینان و لیفت — آشنا شدیم و دیدیم چگونه اصل *Apriori* فضای جستجوی نمایی مجموعه‌های کالا را قابل مدیریت می‌کند. همچنین به‌طور مختصر *FP-Growth* را به‌عنوان جایگزینی کارآمدتر معرفی کردیم. در فصل بعد، به دومین وظیفه اصلی یادگیری بدون نظارت، یعنی خوشه‌بندی، می‌پردازیم.

تمرین‌ها

۱. از میان ۱۰۰۰ تراکنش یک فروشگاه، ۲۰۰ تراکنش شامل «نان» و ۵۰ تراکنش شامل هم «نان» و هم «کره» هستند. پشتیبانی و اطمینان قانون {نان} $\Rightarrow$ {کره} را محاسبه کنید.
۲. اگر پشتیبانی {کره} در کل داده ۱۵ درصد باشد، لیفت قانون تمرین قبل را محاسبه کنید و نتیجه را تفسیر کنید (آیا نان و کره رابطه مثبت، منفی یا مستقل دارند؟).
۳. اصل *Apriori* را با کلمات خودتان توضیح دهید و بگویید چرا این اصل فضای جستجو را به‌شدت کاهش می‌دهد.
۴. چرا یک قانون می‌تواند اطمینان بسیار بالایی داشته باشد (مثلاً ۹۵ درصد) اما از نظر تجاری بی‌ارزش باشد؟ با یک مثال توضیح دهید.
۵. مزیت اصلی *FP-Growth* نسبت به *Apriori* از نظر تعداد بار اسکن کردن داده چیست؟

فصل ۷

خوشه‌بندی

اهداف این فصل

- درک مفهوم خوشه‌بندی و تفاوت آن با طبقه‌بندی
- یادگیری الگوریتم k -means و نحوه انتخاب مقدار k
- آشنایی با خوشه‌بندی سلسله‌مراتبی و روش‌های پیوند
- آشنایی با DBSCAN برای خوشه‌های با شکل دلخواه
- آشنایی با معیارهای ارزیابی خوشه‌بندی

۱.۷ مقدمه‌ای بر خوشه‌بندی

خوشه‌بندی^۱ دومین وظیفه اصلی یادگیری بدون نظارت است. هدف آن، گروه‌بندی نمونه‌ها به گونه‌ای است که نمونه‌های درون یک گروه (خوشه^۲) شباهت زیادی به هم داشته باشند و نمونه‌های دو گروه مختلف، شباهت کمی به یکدیگر داشته باشند — بدون آنکه هیچ برچسب از پیش تعیین شده‌ای در اختیار باشد. این وظیفه با طبقه‌بندی تفاوت اساسی دارد: در طبقه‌بندی، کلاس‌ها از پیش مشخص‌اند و مدل یاد می‌گیرد نمونه جدید به کدام کلاس تعلق دارد؛ در خوشه‌بندی، حتی تعداد و ماهیت گروه‌ها نیز باید از دل خود داده کشف شود.

Clustering^۱
Cluster^۲

کاربردهای رایج خوشه‌بندی عبارت‌اند از بخش‌بندی مشتریان بر اساس رفتار خرید، فشردن سازی تصویر، و به‌عنوان گامی مقدماتی پیش از تحلیل‌های دیگر (مثلاً یافتن زیرگروه‌های همگن در یک جمعیت پیش از مدل‌سازی جداگانه برای هر زیرگروه).

۲.۷ الگوریتم k-means

الگوریتم k-means^۳ پرکاربردترین الگوریتم خوشه‌بندی است. ایده آن ساده است: داده به k خوشه تقسیم می‌شود، به گونه‌ای که هر نمونه به نزدیک‌ترین مرکز خوشه^۴ تعلق داشته باشد. الگوریتم به‌صورت تکرارشونده عمل می‌کند:

۱. ابتدا k مرکز خوشه به‌طور تصادفی انتخاب می‌شوند.
 ۲. هر نمونه به نزدیک‌ترین مرکز خوشه (بر اساس فاصله اقلیدسی) نسبت داده می‌شود.
 ۳. مرکز هر خوشه، به‌عنوان میانگین همه نمونه‌های آن خوشه، دوباره محاسبه می‌شود.
 ۴. مراحل ۲ و ۳ تا زمانی تکرار می‌شوند که مراکز خوشه دیگر تغییر معناداری نکنند (همگرایی).
- هدف k-means کردن مجموع مربعات فاصله درون خوشه‌ای است^۵. نکات مهم عملی:
- چون انتخاب اولیه مراکز تصادفی است، نتیجه نهایی می‌تواند به این انتخاب حساس باشد؛ در عمل الگوریتم چند بار با مقداردهی اولیه متفاوت اجرا و بهترین نتیجه انتخاب می‌شود.
 - k-means برای خوشه‌های با شکل تقریباً کروی و اندازه مشابه بهتر عمل می‌کند و برای خوشه‌های با شکل دلخواه یا اندازه بسیار متفاوت مناسب نیست (بخش ۴.۷ را ببینید).
 - از آنجا که بر پایه فاصله عمل می‌کند، نرمال‌سازی ویژگی‌ها (فصل ۲) پیش از اجرا ضروری است.

انتخاب مقدار k

برخلاف طبقه‌بندی که تعداد کلاس‌ها از قبل مشخص است، در k-means باید مقدار k را از قبل تعیین کنیم. دو روش رایج برای این کار عبارت‌اند از:

k-means Algorithm^۳

Centroid^۴

Within-Cluster Sum of Squares (WCSS)^۵

روش آرنج در روش آرنج^۶، الگوریتم برای مقادیر مختلف k اجرا می‌شود و مقدار WCSS برای هر k رسم می‌شود. با افزایش k ، این مقدار همواره کاهش می‌یابد، اما نرخ کاهش معمولاً در یک نقطه خاص به شدت کم می‌شود و نموداری شبیه آرنج بازو ایجاد می‌کند؛ آن نقطه، انتخاب مناسبی برای k است.

ضریب سیلوئت ضریب سیلوئت^۷ برای هر نمونه، میزان شباهت آن به خوشه خودش را در مقایسه با نزدیک‌ترین خوشه دیگر می‌سنجد و مقداری بین -1 تا 1 می‌دهد؛ مقدار نزدیک به 1 نشان‌دهنده خوشه‌بندی مناسب است. میانگین این ضریب برای همه نمونه‌ها، معیاری کلی برای مقایسه کیفیت خوشه‌بندی با مقادیر مختلف k به دست می‌دهد و برخلاف روش آرنج، نیازی به قضاوت چشمی ندارد.

۳.۷ خوشه‌بندی سلسله‌مراتبی

برخلاف k -means که تعداد خوشه‌ها را از پیش می‌خواهد، خوشه‌بندی سلسله‌مراتبی^۸ ساختاری درختی از خوشه‌ها در سطوح مختلف می‌سازد که با نموداری به نام دندروگرام^۹ نمایش داده می‌شود؛ تعداد نهایی خوشه‌ها را می‌توان بعداً با «بریدن» این درخت در ارتفاع دلخواه تعیین کرد. رایج‌ترین رویکرد، رویکرد تجمیعی^{۱۰} است که به صورت پایین به بالا عمل می‌کند: در ابتدا هر نمونه یک خوشه جداگانه است، و در هر مرحله، دو خوشه نزدیک‌تر به هم ادغام می‌شوند تا در نهایت یک خوشه واحد باقی بماند.

روش‌های پیوند

معیار «نزدیکی» میان دو خوشه (نه دو نمونه منفرد) با روش‌های پیوند^{۱۱} تعریف می‌شود:

- پیوند تک^{۱۲}: کمترین فاصله میان هر عضو یک خوشه با هر عضو خوشه دیگر.
- پیوند کامل^{۱۳}: بیشترین فاصله میان اعضای دو خوشه.
- پیوند میانگین^{۱۴}: میانگین فاصله همه جفت‌های ممکن میان اعضای دو خوشه.

^۶ Elbow Method

^۷ Silhouette Coefficient

^۸ Hierarchical Clustering

^۹ Dendrogram

^{۱۰} Agglomerative Approach

^{۱۱} Linkage Methods

^{۱۲} Single Linkage

^{۱۳} Complete Linkage

^{۱۴} Average Linkage

پیوند تکی می‌تواند به پدیدهٔ زنجیره‌ای شدن^{۱۵} (تشکیل خوشه‌های کشیده و نامناسب) منجر شود، در حالی که پیوند کامل معمولاً خوشه‌های فشرده‌تر و کروی‌تری تولید می‌کند.

۴.۷ DBSCAN

الگوریتم DBSCAN^{۱۶} برخلاف دو روش قبل، خوشه‌ها را بر اساس چگالی نقاط تعریف می‌کند، نه فاصله تا یک مرکز یا ساختار سلسله‌مراتبی. این ویژگی به آن اجازه می‌دهد خوشه‌هایی با شکل دلخواه (نه فقط کروی) را شناسایی کند و به‌طور طبیعی، نقاطی که در هیچ ناحیهٔ پرچگالی قرار نمی‌گیرند را به‌عنوان نویز یا داده پرت علامت‌گذاری کند (که ارتباط مستقیمی با فصل ۸ دارد). DBSCAN دو پارامتر اصلی دارد: شعاع همسایگی (ϵ) و حداقل تعداد نقاط لازم در آن همسایگی برای تشکیل یک ناحیهٔ پرچگالی^{۱۷}. نقاطی که این حداقل تعداد همسایه را در شعاع خود داشته باشند نقاط هسته‌ای^{۱۸} نامیده می‌شوند و خوشه‌ها با اتصال نقاط هسته‌ای مجاور به یکدیگر شکل می‌گیرند.

۵.۷ ارزیابی خوشه‌بندی

از آنجا که در خوشه‌بندی برچسب واقعی وجود ندارد، ارزیابی آن دشوارتر از طبقه‌بندی است. رایج‌ترین رویکرد، استفاده از همان ضریب سیلوئت^{۱۹} است که در بخش انتخاب k دیدیم؛ این معیار می‌تواند برای مقایسهٔ کیفیت هر خوشه‌بندی (فارغ از الگوریتم تولیدکننده) به کار رود. در مواردی که برچسب واقعی (برای اهداف پژوهشی) در دسترس باشد، معیارهایی مانند شاخص رند تعدیل‌شده^{۲۰} نیز برای مقایسهٔ خوشه‌بندی به‌دست‌آمده با برچسب واقعی استفاده می‌شوند.

پیاده‌سازی در پایتون

پیاده‌سازی KMeans، AgglomerativeClustering و DBSCAN از scikit-learn، به‌همراه محاسبهٔ ضریب سیلوئت و رسم دندروگرام، در بخش «فصل ۷» پیوست الف (آ) آمده است.

^{۱۵} Chaining

^{۱۶} Density-Based Spatial Clustering of Applications with Noise

^{۱۷} MinPts

^{۱۸} Core Points

^{۱۹} Silhouette Coefficient

^{۲۰} Adjusted Rand Index

خلاصه فصل

در این فصل با خوشه‌بندی به‌عنوان دومین وظیفه اصلی یادگیری بدون نظارت آشنا شدیم. سه رویکرد اصلی را بررسی کردیم: k -means (مبتنی بر فاصله تا مرکز)، خوشه‌بندی سلسله‌مراتبی (مبتنی بر ساختار درختی و روش‌های پیوند) و DBSCAN (مبتنی بر چگالی). همچنین با روش آرنج و ضریب سیلوئت برای انتخاب تعداد خوشه‌ها و ارزیابی کیفیت خوشه‌بندی آشنا شدیم. در فصل بعد، به موضوع نزدیک به خوشه‌بندی، یعنی تشخیص داده‌های پرت، می‌پردازیم.

تمرین‌ها

۱. تفاوت اصلی خوشه‌بندی با طبقه‌بندی را از نظر نوع داده مورد نیاز (برچسب‌دار در برابر بدون برچسب) توضیح دهید.
۲. چرا نتیجه k -means می‌تواند در دو اجرای مختلف با یک مجموعه داده ثابت، متفاوت باشد؟ چگونه می‌توان این مشکل را کاهش داد؟
۳. تفاوت پیوند تکی و پیوند کامل را با یک مثال از شکل خوشه‌های حاصل توضیح دهید.
۴. چرا DBSCAN می‌تواند خوشه‌هایی با شکل دلخواه را شناسایی کند در حالی که k -means معمولاً خوشه‌های کروی تولید می‌کند؟
۵. توضیح دهید ضریب سیلوئت چگونه هم برای انتخاب مقدار k در k -means و هم برای مقایسه کلی کیفیت خوشه‌بندی به کار می‌رود.

فصل ۸

تشخیص داده‌های پرت

اهداف این فصل

- درک مفهوم داده پرت و تفاوت آن با نویز
- آشنایی با روش‌های آماری ساده برای تشخیص داده پرت
- آشنایی با روش‌های مبتنی بر فاصله و چگالی
- آشنایی با روش‌های مبتنی بر یادگیری ماشین

۱.۸ تعریف و انواع داده‌های پرت

همان‌طور که در فصل ۲ اشاره شد، داده پرت^۱ نمونه‌ای است که به‌طور قابل‌توجهی با بقیه داده تفاوت دارد. برخلاف نویز که معمولاً خطای بی‌معنی و قابل‌حذف است، داده پرت می‌تواند خود هدف اصلی تحلیل باشد. تراکنش متقلبانه در داده‌های بانکی، رفتار غیرعادی یک حسگر پیش از خرابی تجهیزات صنعتی، یا یک بیمار با علائم نادر و نگران‌کننده. به همین دلیل، این وظیفه گاهی تشخیص ناهنجاری^۲ نیز نامیده می‌شود. داده‌های پرت را می‌توان به سه دسته تقسیم کرد:

- پرت سراسری^۳: نمونه‌ای که در مقایسه با کل مجموعه داده غیرعادی است (مثلاً دمای بدن ۴۲ درجه).

^۱ Outlier

^۲ Anomaly Detection

^۳ Global Outlier

- **پرت زمینه‌ای^۴**: نمونه‌ای که تنها در یک زمینه خاص غیرعادی است (مثلاً دمای هوای ۳۵ درجه در زمستان غیرعادی است، اما در تابستان طبیعی است).
- **پرت جمعی^۵**: مجموعه‌ای از نمونه‌ها که هرکدام به تنهایی عادی به نظر می‌رسند، اما رفتار جمعی آن‌ها غیرعادی است (مثلاً یک الگوی ترافیک شبکه که نشانه حمله سایبری است).

۲.۸ روش‌های آماری

ساده‌ترین رویکرد برای تشخیص داده پرت، استفاده از فرضیات آماری درباره توزیع داده است. برای داده‌ای که تقریباً توزیع نرمال دارد، رایج‌ترین روش استفاده از امتیاز Z ^۶ است (که پیش‌تر در فصل ۲ برای استانداردسازی دیدیم): نمونه‌ای که قدرمطلق امتیاز Z آن بیش از یک آستانه (معمولاً ۵.۲ یا ۳) باشد، به عنوان داده پرت علامت‌گذاری می‌شود.

روش دیگر که وابستگی کمتری به فرض نرمال بودن توزیع دارد، استفاده از دامنه میان‌چارکی^۷ است: هر مقداری که خارج از بازه $[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$ قرار گیرد (که در آن Q_1 و Q_3 به ترتیب چارک اول و سوم داده‌اند)، به عنوان پرت در نظر گرفته می‌شود. این روش پایه نمودار جعبه‌ای است.^۸

محدودیت اصلی روش‌های آماری این است که معمولاً فقط برای یک ویژگی در یک زمان مناسب‌اند (تک‌متغیره) و به سختی به داده‌های چندبعدی با روابط پیچیده میان ویژگی‌ها تعمیم می‌یابند.

۳.۸ روش‌های مبتنی بر فاصله و چگالی

روش‌های مبتنی بر فاصله، داده پرت را نمونه‌ای تعریف می‌کنند که همسایگان نزدیک کمی دارد یا فاصله آن تا نزدیک‌ترین همسایه‌هایش زیاد است — رویکردی مشابه چیزی که در DBSCAN (فصل ۷) دیدیم، که در آن نقاط کم‌چگالی به‌طور طبیعی به عنوان نویز شناسایی می‌شدند.

روش دقیق‌تری که چگالی نسبی را در نظر می‌گیرد، عامل پرت محلی^۹ نام دارد. مزیت اصلی LOF نسبت به روش‌های ساده‌تر این است که چگالی هر نقطه را نسبت به چگالی همسایگانش می‌سنجد، نه نسبت به یک آستانه سراسری ثابت؛ این ویژگی به آن اجازه می‌دهد داده‌های پرت را

Contextual Outlier^۴Collective Outlier^۵Z-Score^۶Interquartile Range (IQR)^۷Box Plot^۸Local Outlier Factor (LOF)^۹

حتی در مجموعه‌هایی که چگالی خوشه‌های مختلف با هم تفاوت دارد (که در آن‌ها روش‌های سراسری‌تر دچار خطا می‌شوند)، به‌درستی شناسایی کند.

۴.۸ روش‌های مبتنی بر یادگیری

جنگل ایزوله^{۱۰} یکی از مؤثرترین روش‌های مدرن تشخیص داده پرت است. ایده اصلی آن برخلاف روش‌های قبلی که بر پایه فاصله یا چگالی «عادی بودن» را می‌سنجیدند، مستقیماً بر پایه سهولت ایزوله کردن یک نمونه است: با ساخت درخت‌های تصادفی که به‌طور مکرر داده را بر اساس ویژگی‌ها و مقادیر تصادفی تقسیم می‌کنند، نمونه‌های پرت — که از بقیه داده متمایزند — معمولاً با تعداد تقسیم بسیار کمتری ایزوله می‌شوند (یعنی در عمق کمتری از درخت به تنهایی قرار می‌گیرند)، در حالی که نمونه‌های عادی برای ایزوله شدن به تقسیم‌های بیشتری نیاز دارند. میانگین عمق ایزوله‌سازی روی چند درخت تصادفی، امتیاز پرت بودن هر نمونه را می‌دهد. مزیت اصلی جنگل ایزوله نسبت به روش‌های مبتنی بر فاصله (مانند، LOF) کارایی محاسباتی بهتر آن روی داده‌های با ابعاد بالا و حجم زیاد است، زیرا نیازی به محاسبه فاصله جفت‌به‌جفت میان همه نمونه‌ها ندارد.

پیاده‌سازی در پایتون

پیاده‌سازی IsolationForest و LocalOutlierFactor از scikit-learn، به‌همراه محاسبه امتیاز Z و دامنه میان‌چارکی با pandas/numpy، در بخش «فصل ۸» پیوست الف (آ) آمده است.

خلاصه فصل

در این فصل با مفهوم داده پرت، سه نوع اصلی آن (سراسری، زمینه‌ای، جمعی) و طیفی از روش‌های تشخیص آن — از روش‌های آماری ساده (امتیاز Z ، دامنه میان‌چارکی) تا روش‌های مبتنی بر چگالی (LOF) و روش‌های مدرن مبتنی بر یادگیری (جنگل ایزوله) — آشنا شدیم. با این فصل، بخش «یادگیری بدون نظارت» این کتاب تکمیل می‌شود. در فصل بعد، به‌طور مختصر به دو حوزه تکمیلی، یعنی داده کاوی متن و وب، می‌پردازیم.

^{۱۰} Isolation Forest

تمرین‌ها

۱. برای هر یک از مثال‌های زیر مشخص کنید که به کدام نوع داده پرت (سراسری، زمینه‌ای یا جمعی) نزدیک‌تر است: (الف) خرید ناگهانی و بسیار بزرگ روی یک کارت اعتباری در نیمه شب، (ب) یک روز با دمای ۳۰ درجه در وسط زمستان، (ج) یک سری کوتاه از درخواست‌های شبکه با الگوی غیرعادی که نشانه حمله است.
۲. چرا روش‌های آماری تک‌متغیره (مانند امتیاز Z) برای داده‌های چندبعدی با روابط پیچیده میان ویژگی‌ها کافی نیستند؟
۳. تفاوت اصلی LOF با روش‌های ساده‌تر مبتنی بر فاصله (مانند فاصله تا k اُمین همسایه نزدیک) را در مواجهه با خوشه‌هایی با چگالی متفاوت توضیح دهید.
۴. ایده اصلی جنگل ایزوله را در یک یا دو جمله توضیح دهید و بگویید چرا این ایده برای داده‌های با ابعاد بالا کارآمد است.
۵. یک سناریوی واقعی (غیر از مثال‌های این فصل) پیدا کنید که در آن تشخیص داده پرت اهمیت عملی داشته باشد و توضیح دهید کدامیک از روش‌های این فصل برای آن مناسب‌تر است.

بخش چهارم

موضوعات تکمیلی

فصل ۹

مقدمه‌ای بر داده‌کاوی متن و وب

اهداف این فصل

- آشنایی با گام‌های اصلی پیش‌پردازش متن
- یادگیری بازنمایی متن به صورت عددی (Bag-of-Words) و (TF-IDF)
- آشنایی مقدماتی با کاربرد طبقه‌بندی و خوشه‌بندی روی متن
- آشنایی کلی با مفاهیم پایه داده‌کاوی وب

۱.۹ چرا متن به رفتار متفاوتی نیاز دارد؟

تمام الگوریتم‌هایی که تاکنون دیدیم (درخت تصمیم، k -NN k -means و مانند آن‌ها) به یک بازنمایی عددی و با ابعاد ثابت از هر نمونه نیاز دارند. اما متن خام — یک ایمیل، یک نظر مشتری، یک مقاله خبری — رشته‌ای از کلمات با طول متغیر است که مستقیماً قابل استفاده در این الگوریتم‌ها نیست. بنابراین اولین گام در هر پروژه داده‌کاوی متن^۱، تبدیل متن به یک بازنمایی عددی مناسب است.

۲.۹ پیش‌پردازش متن

پیش از تبدیل متن به بردار عددی، معمولاً چند گام پیش‌پردازش زیر انجام می‌شود:

^۱Text Mining

- **نشانه‌گذاری^۲:** شکستن متن به واحدهای کوچک‌تر، معمولاً کلمات یا زیرکلمات^۳.
- **حذف ایست‌واژه‌ها^۴:** حذف کلمات بسیار پرتکرار و کم‌اطلاعات مانند حروف اضافه و ضمایر (مثلاً «را»، «به»، «از» در فارسی، یا «the» «is» در انگلیسی) که معمولاً برای تشخیص موضوع متن مفید نیستند.
- **ریشه‌یابی^۵ یا بن‌واژه‌یابی^۶:** تبدیل کلمات مختلف با ریشه مشترک به یک شکل واحد (مثلاً «رفتن»، «می‌رود»، «رفت» به یک ریشه مشترک)، تا الگوریتم آن‌ها را یک مفهوم واحد در نظر بگیرد.
- **نرمال‌سازی متن:** تبدیل به حروف کوچک (در زبان‌های لاتین)، حذف علائم نگارشی و اعداد نامرتب.

۳.۹ بازنمایی متن به صورت عددی

کیسه کلمات

ساده‌ترین روش بازنمایی متن، **کیسه کلمات^۷** است: هر سند با یک بردار به طول واژگان کل مجموعه داده نمایش داده می‌شود که هر درایه آن، تعداد تکرار یک کلمه خاص در آن سند است. نام «کیسه» به این دلیل است که این روش کاملاً ترتیب کلمات را نادیده می‌گیرد؛ برای این روش، جمله «سگ گربه را دنبال کرد» و «گربه سگ را دنبال کرد» کاملاً یکسان دیده می‌شوند.

TF-IDF

مشکل اصلی کیسه کلمات این است که به کلمات بسیار پرتکرار (که لزوماً اطلاعات زیادی درباره موضوع سند نمی‌دهند) وزن بیش از حد می‌دهد. **TF-IDF^۸** این مشکل را با ترکیب دو عامل حل می‌کند:

- **فراوانی واژه^۹:** تعداد تکرار یک کلمه در یک سند خاص (هرچه بیشتر، وزن بیشتر).

Tokenization^۲

Tokens^۳

Stop-word Removal^۴

Stemming^۵

Lemmatization^۶

Bag-of- Words (BoW)^۷

Term Frequency-Inverse Document Frequency^۸

Term Frequency (TF)^۹

- **فراوانی معکوس سند^{۱۰}**: هرچه یک کلمه در تعداد کمتری از اسناد کل مجموعه ظاهر شود، وزن بیشتری می‌گیرد؛ کلماتی که تقریباً در همه اسناد تکرار می‌شوند (مانند حروف اضافه باقی‌مانده)، وزن بسیار کمی می‌گیرند.

وزن نهایی هر کلمه در هر سند، حاصل ضرب این دو مقدار است:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$$

این بازنمایی، پرکاربردترین روش کلاسیک برای تبدیل متن به بردار عددی است و پایه بسیاری از موتورهای جستجو و سیستم‌های بازیابی اطلاعات نیز همین ایده است.^{۱۱}

۴.۹ کاربردهای مقدماتی

پس از بازنمایی متن به صورت بردار عددی (با TF-IDF یا کیسه کلمات)، می‌توان مستقیماً از الگوریتم‌های فصل‌های قبل استفاده کرد:

- **طبقه‌بندی متن**: مثلاً تشخیص اسپم یا تحلیل احساسات (مثبت/منفی/خنثی بودن یک نظر مشتری) با استفاده از بیز ساده یا ماشین بردار پشتیبان.
- **خوشه‌بندی متن**: گروه‌بندی خودکار مقالات خبری بر اساس موضوع، بدون داشتن برچسب از پیش، با استفاده از k-means روی بردارهای TF-IDF.

نکته مهم این است که بردارهای حاصل از متن معمولاً ابعاد بسیار بالا (به تعداد کل کلمات منحصر به فرد واژگان) و بسیار پراکنده دارند (اکثر درایه‌ها صفرند، چون هر سند فقط شامل بخش کوچکی از کل واژگان است)؛ به همین دلیل، همان‌طور که در فصل ۲ دیدیم، شباهت کسینوسی معمولاً معیار مناسب‌تری نسبت به فاصله اقلیدسی برای مقایسه این بردارهاست.

۵.۹ مقدمه‌ای بر داده‌کاوی وب

داده‌کاوی وب^{۱۲} به کاربرد تکنیک‌های داده‌کاوی بر روی داده‌های وب اشاره دارد و معمولاً به سه زیرشاخه تقسیم می‌شود:

- **کاوش محتوای وب^{۱۳}**: استخراج دانش از محتوای صفحات وب (متن، تصویر)، که عملاً تعمیمی از داده‌کاوی متن به مقیاس وب است.

^{۱۰} Inverse Document Frequency (IDF)

^{۱۱} Information Retrieval

^{۱۲} Web Mining

^{۱۳} Web Content Mining

- کاوش ساختار وب^{۱۴}: تحلیل گراف پیوندهای میان صفحات وب (مثلاً الگوریتم‌هایی شبیه PageRank که برای رتبه‌بندی صفحات از ساختار پیوندها استفاده می‌کنند).
- کاوش استفاده از وب^{۱۵}: تحلیل رفتار کاربران در یک وب‌سایت (مانند مسیر کلیک‌ها) برای بهبود طراحی سایت یا سیستم‌های توصیه‌گر.

پرداختن کامل به این حوزه از حوصله این کتاب مقدماتی خارج است، اما آشنایی با این تقسیم‌بندی برای شناخت جایگاه داده‌کاوی متن در تصویر بزرگ‌تر مفید است.

پیاده‌سازی در پایتون

پیاده‌سازی TfIdfVectorizer و CountVectorizer از scikit-learn، به همراه یک مثال کامل طبقه‌بندی متن، در بخش «فصل ۹» پیوست الف (آ) آمده است.

خلاصه فصل

در این فصل با چالش اصلی کار با داده‌های متنی — نیاز به تبدیل متن به بازنمایی عددی — آشنا شدیم. گام‌های پیش‌پردازش متن، کیسه کلمات و TF-IDF را بررسی کردیم و دیدیم چگونه پس از این تبدیل، می‌توان از همان الگوریتم‌های طبقه‌بندی و خوشه‌بندی فصل‌های قبل روی متن استفاده کرد. در پایان، نگاهی کلی به سه زیرشاخه داده‌کاوی وب انداختیم. در فصل پایانی کتاب، به‌طور مقدماتی با داده‌های پیچیده‌تر (گراف و سری زمانی) آشنا خواهیم شد.

تمرین‌ها

۱. چرا نمی‌توان متن خام را مستقیماً به یک الگوریتم مانند درخت تصمیم یا k-means داد؟
۲. دو نمونه از ایست‌واژه‌های فارسی را نام ببرید و توضیح دهید چرا حذف آن‌ها معمولاً به بهبود کیفیت مدل کمک می‌کند.
۳. فرض کنید کلمه «کامپیوتر» در یک سند خاص ۵ بار تکرار شده، اما در تقریباً همه اسناد مجموعه نیز حضور دارد. وزن TF-IDF این کلمه چه تفاوتی با کلمه‌ای کمیاب‌تر اما با همان فراوانی خواهد داشت؟

^{۱۴} Web Structure Mining

^{۱۵} Web Usage Mining

۴. چرا شباهت کسینوسی برای مقایسه بردارهای TF-IDF مناسب‌تر از فاصله اقلیدسی است؟

۵. تفاوت کاوش محتوای وب و کاوش ساختار وب را با یک مثال از هرکدام توضیح دهید.

فصل ۱۰

مقدمه‌ای بر داده‌های پیچیده

اهداف این فصل

- آشنایی مقدماتی با داده‌کاوی گراف
- آشنایی مقدماتی با تحلیل سری‌های زمانی
- آشنایی با مسیرهای پیشرفته‌تر برای ادامه یادگیری

۱.۱۰ فراتر از داده‌های جدولی

در تمام فصل‌های پیشین، فرض بر این بود که داده به صورت جدولی است: هر سطر یک نمونه مستقل و هر ستون یک ویژگی. بسیاری از داده‌های واقعی، اما، ساختاری فراتر از این دارند — روابط میان نمونه‌ها (مانند شبکه‌های اجتماعی) یا ترتیب زمانی میان مشاهدات (مانند قیمت سهام). این فصل پایانی، به صورت مقدماتی و صرفاً برای آشنایی، دو نوع از این داده‌های پیچیده‌تر را معرفی می‌کند تا خواننده افق‌های بعدی مطالعه را بشناسد.

۲.۱۰ داده‌کاوی گراف

در بسیاری از مسائل، داده به طور طبیعی به صورت **گراف**^۱ — مجموعه‌ای از گره‌ها^۲ و یال‌ها^۳ میان آن‌ها — بازنمایی می‌شود: کاربران یک شبکه اجتماعی و روابط دوستی میانشان، صفحات وب

Graph^۱
Nodes / Vertices^۲
Edges^۳

و پیوندهای میانشان، یا مولکول‌ها و پیوندهای شیمیایی. داده‌کاوی گراف^۴ به کشف الگو در این نوع داده می‌پردازد. برخی از سؤالات رایج در این حوزه عبارت‌اند از:

- **تشخیص اجتماع^۵:** یافتن گروه‌هایی از گره‌ها که درون خود پیوندهای متراکم‌تری نسبت به بیرون دارند — مفهومی که شباهت زیادی به خوشه‌بندی (فصل ۷) دارد، با این تفاوت که ورودی آن روابط میان نمونه‌هاست، نه ویژگی‌های عددی هر نمونه.
- **مرکزیت گره^۶:** سنجش میزان اهمیت یا نفوذ هر گره در گراف (مثلاً شناسایی کاربران تأثیرگذار در یک شبکه اجتماعی).
- **پیش‌بینی پیوند^۷:** پیش‌بینی این‌که کدام یال‌های جدید در آینده به گراف اضافه خواهند شد (مثلاً پیشنهاد دوستی در شبکه‌های اجتماعی).

۳.۱۰ تحلیل سری‌های زمانی

سری زمانی^۸ دنباله‌ای از مشاهدات است که به ترتیب زمانی ثبت شده‌اند (مثلاً دمای روزانه، قیمت سهام، یا میزان فروش ماهانه). تفاوت اساسی این نوع داده با داده‌های جدولی معمولی، وجود وابستگی زمانی میان مشاهدات متوالی است؛ برخلاف فرض رایج در بسیاری از الگوریتم‌های پیشین این کتاب که نمونه‌ها را مستقل از هم در نظر می‌گرفتند.

تجزیه سری زمانی^۹ یک سری زمانی را معمولاً به سه مؤلفه اصلی تجزیه می‌کند:

- **روند^{۱۰}:** تغییر کلی و بلندمدت (صعودی یا نزولی) در داده.
- **فصلی بودن^{۱۱}:** الگوهای تکرارشونده در بازه‌های زمانی ثابت (مثلاً افزایش فروش هر سال در نزدیکی یک مناسبت خاص).
- **باقیمانده^{۱۲}:** نوسانات تصادفی باقی‌مانده پس از کنار گذاشتن روند و فصلی بودن.

Graph Mining^۴

Community Detection^۵

Centrality^۶

Link Prediction^۷

Time Series^۸

Time Series Decomposition^۹

Trend^{۱۰}

Seasonality^{۱۱}

Residual^{۱۲}

برای پیش‌بینی مقادیر آینده یک سری زمانی، از مدل‌های کلاسیکی مانند $ARIMA^{۱۳}$ تا روش‌های مدرن مبتنی بر یادگیری عمیق (مانند شبکه‌های بازگشتی^{۱۴}) استفاده می‌شود که بررسی کامل آن‌ها خارج از حوصله این کتاب مقدماتی است.

۴.۱۰ جمع‌بندی و مسیرهای پیشرفته‌تر

در طول این کتاب، مسیری از مفاهیم پایه (فصل ۱ و ۲)، از میان یادگیری با نظارت (طبقه‌بندی و رگرسیون در فصل‌های ۳ تا ۵)، تا یادگیری بدون نظارت (قوانین انجمنی، خوشه‌بندی و تشخیص داده پرت در فصل‌های ۶ تا ۸)، و در پایان مقدمه‌ای بر داده‌های متنی و پیچیده (فصل‌های ۹ و ۱۰) طی کردیم. این کتاب صرفاً نقطه شروع است؛ برای ادامه مسیر، خواننده می‌تواند به سراغ موضوعاتی مانند یادگیری عمیق، یادگیری تقویتی، پردازش زبان طبیعی مدرن (بر پایه ترنسفورمرها)، و مقیاس‌پذیری داده‌کاوی روی داده‌های عظیم (با ابزارهایی مانند Spark) برود. مراجع اصلی این کتاب — Han/Kamber/Pei و Tan/Steinbach/Kumar — نیز برای مطالعه عمیق‌تر هر یک از فصل‌های این کتاب به‌شدت توصیه می‌شوند.

تمرین‌ها

۱. شباهت و تفاوت «تشخیص اجتماع» در گراف با «خوشه‌بندی» در فصل ۷ را توضیح دهید.
۲. یک مثال واقعی از پیش‌بینی پیوند در یک شبکه اجتماعی که با آن آشنایی دارید، بیان کنید.
۳. برای فروش ماهانه یک فروشگاه لباس، مؤلفه‌های روند، فصلی بودن و باقیمانده را با یک مثال فرضی توضیح دهید.
۴. چرا فرض استقلال نمونه‌ها که در بسیاری از الگوریتم‌های فصل‌های قبل وجود داشت، برای داده‌های سری زمانی مناسب نیست؟
۵. با توجه به علایق خودتان، یکی از مسیرهای پیشرفته‌تر معرفی‌شده در این فصل (یادگیری عمیق، یادگیری تقویتی، پردازش زبان طبیعی مدرن، یا داده‌کاوی مقیاس‌بزرگ) را انتخاب کنید و توضیح دهید چرا برای ادامه مطالعه به آن علاقه‌مندید.

^{۱۳} AutoRegressive Integrated Moving Average

^{۱۴} Recurrent Neural Networks (RNN)

پیوست آ

پایتون برای داده کاوی

این پیوست شامل پیاده‌سازی عملی مثال‌های هر فصل با استفاده از کتابخانه‌های pandas، numpy، scikit-learn، matplotlib و mlxtend است. کد کامل هر بخش در پوشه textttcode مخزن گیت‌هاب قرار دارد و در اینجا تنها بخش‌های کلیدی برای تطبیق با متن کتاب آورده شده‌اند.

۱.آ آماده‌سازی محیط

```
keywordstyle
| dnetxlm biltolptam nrael-tikics ypmun sadnap llatsni pip | ۱
```

۲.آ فصل ۲ — پیش‌پردازش داده

```
keywordstyle
| dp sa sadnap tropmi | ۱
| relacSdradnatS tropmi gnissecorperp.nraelks morf | ۲
| ACP tropmi noitisopmoted.nraelks morf | ۳
| ۴
| "vsc.atad"(vsc_daer.dp = fd | ۵
| )(anpord.fd = fd | ۶
| ۷
| )(relacSdradnatS = relacs | ۸
```

```

|=edulcni(sepytd_tceles.fd(mrofsnart_tif.relacs = delacs_X| ۹
                    ))"rebmun |
                    | ۱۰
                    )2=stnenopmoc_n(ACP = acp| ۱۱
                    )delacs_X(mrofsnart_tif.acp = acp_X| ۱۲

```

۳. آ. فصل ۳ و ۴ — طبقه بندی

```

keywordstyle
reiffissalCeerTnoisiced tropmi eert.nraelks morf| ۱
BNnaissuaG tropmi seyab_evian.nraelks morf| ۲
reiffissalCsrobhgieNK tropmi srobhgien.nraelks morf| ۳
CVS tropmi mvs.nraelks morf| ۴
reiffissalCtseroFmodnaR tropmi elbmesne.nraelks morf| ۵
tilps_tset_niart tropmi noitceles_ledom.nraelks morf| ۶
,troper_noitacifissalc tropmi scirtem.nraelks morf| ۷
erocs_cua_cor |
| ۸
,y ,X(tilps_tset_niart = tset_y ,niart_y ,tset_X ,niart_X| ۹
)2.0=ezis_tset |
| ۱۰
)5=htped_xam(reiffissalCeerTnoisiced = flc| ۱۱
)niart_y ,niart_X(tif.flc| ۱۲
)))tset_X(tciderp.flc ,tset_y(troper_noitacifissalc(tnirp| ۱۳

```

۴. آ. فصل ۶ — قوانین انجمنی

```

keywordstyle
,iroirpa tropmi snrettap_tneuqerf.dnetxlm morf| ۱
selur_noitaicossa |
| ۲
,50.0=troppus_nim ,fd_teksab(iroirpa = stesmeti_tneuqerf| ۳
)eurT=semanloc_esu |

```

```
"=cirtem ,stesmeti_tneuqerf(selur_noitaicossa = selur| ۴
)6.0=dlohserht_nim ,"ecnedifnoc |
```

۵.آ فصل ۷ — خوشه‌بندی

```
keywordstyle
,NACSBd ,snaeMK tropmi retsulc.nraelks morf| ۱
gniretsulCevitaremolggA |
| ۲
(tif.)24=etats_modnar ,3=sretsulc_n(snaeMK = snaemk| ۳
)delacs_X |
)delacs_X(tif.)5=selpmas_nim ,5.0=spe(NACSBd = nacsbd| ۴
```

۶.آ فصل ۸ — تشخیص داده‌های پرت

```
keywordstyle
tseroFnoitalosI tropmi elbmesne.nraelks morf| ۱
rotcaFreiltuOlacoL tropmi srobhgien.nraelks morf| ۲
| ۳
)delacs_X(tif.)50.0=noitanimatnoc(tseroFnoitalosI = osi| ۴
)02=srobhgien_n(rotcaFreiltuOlacoL = fol| ۵
)delacs_X(tciderp_tif.fol = sreiltuo| ۶
```

۷.آ فصل ۹ — داده‌کاوی متن

```
keywordstyle
tropmi txet.noitcartxe_erutaef.nraelks morf| ۱
rezirotceVfdifT |
| ۲
)"hsilgne"=sdrow_pots(rezirotceVfdifT = rezirotcev| ۳
)suproc(mrofnsart_tif.rezirotcev = txet_X| ۴
```

پیوست آ. پائتون برای داده کاوی

پیوست ب

دیتاست‌های تمرینی

در این پیوست فهرستی از دیتاست‌های عمومی و رایگان معرفی می‌شود که برای تمرین‌های هر فصل مناسب هستند (مثلاً از UCI Repository Learning Machine و Kaggle لینک دقیق هر دیتاست و اسکرپت دانلود آن در پوشهٔ data/ مخزن گیت‌هاب قرار می‌گیرد).

- فصل ۳ و ۴ (طبقه‌بندی): Census Adult Iris (Income)
- فصل ۵ (رگرسیون): Housing Boston/California
- فصل ۶ (قوانین انجمنی): Dataset Retail Online
- فصل ۷ و ۸ (خوشه‌بندی و داده پرت): Fraud Card Credit Customers, Mall
- فصل ۹ (متن): ۲۰ Newsgroups